

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO

CENTRO TECNOLÓGICO

COLEGIADO DO CURSO DE ENGENHARIA DE COMPUTAÇÃO

Hugo Lima Otoch Demétrio de Souza

Avaliação da generalização de modelos de aprendizado de máquina com base em diferentes domínios de representação de lesões de pele

Vitória, ES

2026

Hugo Lima Otoch Demétrio de Souza

Avaliação da generalização de modelos de aprendizado de máquina com base em diferentes domínios de representação de lesões de pele

Monografia apresentada ao Colegiado do Curso de Engenharia de Computação do Centro Tecnológico da Universidade Federal do Espírito Santo, como requisito parcial para obtenção do Grau de Bacharel em Engenharia de Computação.

Universidade Federal do Espírito Santo – UFES

Centro Tecnológico

Colegiado do Curso de Engenharia de Computação

Orientador: Prof. Luis Antonio de Souza Júnior

Vitória, ES

2026

Hugo Lima Otoch Demétrio de Souza

Avaliação da generalização de modelos de aprendizado de máquina com base em diferentes domínios de representação de lesões de pele/ Hugo Lima Otoch Demétrio de Souza. – Vitória, ES, 2026-

58 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Luis Antonio de Souza Júnior

Monografia (PG) – Universidade Federal do Espírito Santo – UFES
Centro Tecnológico
Colegiado do Curso de Engenharia de Computação, 2026.

1. Inteligência artificial. 2. Aprendizado profundo. 3. Câncer de pele. 4. Visão computacional. I. Universidade Federal do Espírito Santo. II. Avaliação da generalização de modelos de aprendizado de máquina com base em diferentes domínios de representação de lesões de pele

CDU 02:141:005.7

Hugo Lima Otoch Demétrio de Souza

Avaliação da generalização de modelos de aprendizado de máquina com base em diferentes domínios de representação de lesões de pele

Monografia apresentada ao Colegiado do Curso de Engenharia de Computação do Centro Tecnológico da Universidade Federal do Espírito Santo, como requisito parcial para obtenção do Grau de Bacharel em Engenharia de Computação.

Trabalho aprovado. Vitória, ES, 26 de fevereiro de 2026:

Prof. Luis Antonio de Souza Júnior
Orientador

Prof. Saulo Bortolon
Convidado 1

Prof. Bruno Légora
Convidado 2

Vitória, ES
2026

Dedico este trabalho a todos que me estenderam a mão
quando o caminho parecia longo demais.

Agradecimentos

Quero expressar minha profunda gratidão a todos que caminharam ao meu lado durante esta jornada. Mesmo nos momentos de incerteza, o apoio de vocês foi a força necessária para seguir em frente.

Ao meu pai, meu maior exemplo de caráter e profissionalismo. Obrigado por ser meu norte, me orientando e me acolhendo nos momentos em que me senti perdido.

À minha mãe, que mesmo à distância, fez-se presente em cada passo. Sua força e sacrifício são minha inspiração diária, e tudo o que conquisto é uma forma de tentar retribuir o imenso amor que sempre recebi.

À minha noiva, meu porto seguro e companheira de todas as horas. Obrigado por me guiar com sabedoria, por me encorajar incansavelmente e por ser a peça fundamental para que eu mantivesse o foco e a esperança em um desfecho feliz.

Ao meu orientador, pela generosidade em aceitar me conduzir neste trabalho. Agradeço pela paciência, pela calma e pela dedicação inabalável, especialmente diante dos percalços técnicos que enfrentamos.

Aos meus amigos, tanto os que compartilharam as salas de aula quanto os que dividiram a vida fora delas. A presença de vocês tornou o fardo mais leve e a caminhada muito mais significativa.

Aos meus professores, por compartilharem não apenas conhecimento técnico, mas experiências de vida que levarei para sempre em minha carreira.

Por fim, agradeço a todas as pessoas que, direta ou indiretamente, contribuíram para a realização deste sonho. Serei eternamente grato.

"O sucesso não é final, o fracasso não é fatal:
o que conta é a coragem de continuar."
(Winston Churchill)

Resumo

A disparidade visual entre imagens dermatoscópicas controladas e fotografias clínicas obtidas por *smartphones* impõe barreiras críticas à aplicação de inteligência artificial no diagnóstico de câncer de pele. Para investigar essa barreira, este estudo avalia a generalização de redes neurais profundas quando submetidas ao fenômeno de *domain shift* entre imagens clínicas e dermatoscópicas, avaliando as arquiteturas ResNet-50, ResNet-101, MobileNetV3 e *Vision Transformer*. A metodologia estruturou-se em três abordagens experimentais progressivas: a primeira estabeleceu a linha de base intra-domínio, treinando e testando modelos na mesma modalidade; a segunda simulou cenários de transferência cruzada (*cross-domain*), aplicando modelos treinados em um domínio diretamente no outro; e a terceira investigou o treinamento com dataset unificado, combinando as bases clínicas e dermatoscópicas para verificar a hipótese de ganho de desempenho via diversidade de dados. Os resultados apontaram a ResNet-101 como a arquitetura mais eficaz entre as avaliadas. As análises estatísticas confirmaram que a transferência direta de conhecimento entre domínios distintos causa degradação severa de desempenho. Além disso, a abordagem de treinamento unificado revelou que a simples agregação de dados heterogêneos não resultou em ganho de precisão diagnóstica, mantendo métricas similares ou ligeiramente inferiores às obtidas pelos modelos especialistas intra-domínio.

Palavras-chaves: Câncer de Pele. Aprendizado Profundo. Classificação de Imagens. Generalização de Domínio. Dermatoscopia. Imagens Clínicas.

Lista de ilustrações

Figura 1 – Estrutura de um neurônio biológico. 18
Figura 2 – Rede Neural Simples 19
Figura 3 – Max Pooling 21
Figura 4 – Transformer : Arquitetura do Modelo 24
Figura 5 – Arquitetura do Vision Transformer 25
Figura 6 – Exemplo de cada lesão de pele presente no *dataset* ISIC19 31
Figura 7 – Exemplo de cada lesão de pele presente no *dataset* PAD-UFES-20+ . . 33
Figura 8 – Distribuição de diagnósticos padronizados no *dataset* PAD-UFES-20+. 34
Figura 9 – Figura ilustrativa da primeira abordagem. 38
Figura 10 – Figura ilustrativa da segunda abordagem 40
Figura 11 – Figura ilustrativa da terceira abordagem 41
Figura 12 – Fluxo do Stratified Group K-Fold com Filtragem Dinâmica 42
Figura 13 – Desempenho da ResNet-101 no Domínio Dermatoscópico. 46
Figura 14 – Desempenho da ResNet-101 no Domínio Clínico. 48
Figura 15 – Resultados da ResNet-101 no cenário Cross-Domain (Clínico → Dermatoscópico). 49
Figura 16 – Resultados da ResNet-101 no cenário Cross-Domain (Dermatoscópico → Clínico). 50
Figura 17 – Resultados da ResNet-101 (Treino Unificado) testada no Domínio Dermatoscópico para a abordagem 3. 51
Figura 18 – Resultados da ResNet-101 (Treino Unificado) testada no Domínio Clínico para a abordagem 3. 52

Lista de tabelas

Tabela 1 – Distribuição quantitativa de classes segmentada por tipo de imagem no *dataset* unificado. 35
Tabela 2 – Padronização dos hiperparâmetros e protocolos de treinamento. 44
Tabela 3 – Consolidação dos resultados obtidos em todas as abordagens experimentais. 45

Lista de abreviaturas e siglas

ACC	Acurácia Global
AK	Ceratose Actínica
AUC	Área Sob a Curva
BACC	Acurácia Balanceada
BCC	Carcinoma Basocelular
BKL	Ceratose Benigna
CID-10	Classificação Internacional de Doenças (10ª Revisão)
CNN	Rede Neural Convolucional
DF	Dermatofibroma
EDA	Análise Exploratória de Dados
ISIC	*International Skin Imaging Collaboration*
LR	Taxa de Aprendizado
MEL	Melanoma
NV	Nevo Melanocítico
OOD	Fora da Distribuição
ROC	Característica de Operação do Receptor
SCC	Carcinoma Espinocelular
VASC	Lesão Vascular
ViT	*Vision Transformer*

Sumário

1 INTRODUÇÃO . . . 13
1.1 Motivação e Justificativa . . . 13
1.2 Hipótese . . . 14
1.3 Objetivo . . . 15

2 REFERENCIAL TEÓRICO E TECNOLOGIAS UTILIZADAS . . . 16
2.1 Inteligência Artificial e Aprendizado de Máquina . . . 16
2.1.1 Aprendizado de Máquina como um subcampo da IA . . . 17
2.1.2 Tipos de Aprendizado: Supervisionado, Não Supervisionado e por Reforço . . . 17
2.2 Redes Neurais e Aprendizado Profundo (*Deep Learning*) . . . 17
2.2.1 O Neurônio Artificial: Perceptron . . . 18
2.2.2 Arquitetura de Redes Neurais: Camadas e Funções de Ativação . . . 18
2.2.3 O Processo de Treinamento: Backpropagation e Otimizadores . . . 19
2.3 Redes Neurais Convolucionais (CNNs) . . . 20
2.3.1 A Operação de Convolução para Extração de Características . . . 20
2.3.2 Camadas de Agrupamento (*Pooling*) . . . 20
2.3.3 Aprendizagem por Transferência e Ajuste Fino (*Fine-Tuning*) . . . 21
2.3.4 Arquiteturas Clássicas . . . 22
2.4 *Vision Transformers* (ViT) . . . 23
2.4.1 A Arquitetura Transformer e o Mecanismo de Atenção . . . 23
2.4.2 A Adaptação para Visão Computacional: O Vision Transformer (ViT) . . . 24
2.5 Ferramentas Utilizadas . . . 26
2.6 Trabalhos Correlatos . . . 26

3 METODOLOGIA . . . 30
3.1 Visão Geral . . . 30
3.2 Bases de Dados e Análise Exploratória . . . 30
3.2.1 ISIC 2019 . . . 31
3.2.1.1 Distribuição de Classes e Desbalanceamento . . . 31
3.2.2 PAD-UFES-20+ . . . 32
3.2.2.1 Mapeamento de Classes e Interoperabilidade . . . 32
3.2.2.2 Distribuição e Desbalanceamento . . . 34
3.3 Unificação dos Datasets . . . 34
3.3.1 Processo de Padronização e Integração . . . 35
3.3.2 Perfil do Dataset Híbrido . . . 35
3.4 Métricas de Avaliação . . . 36

3.4.1 Acurácia (*Accuracy*) . . . 36
3.4.2 Acurácia Balanceada (*Balanced Accuracy* - BACC) . . . 36
3.4.3 Área Sob a Curva ROC (*Area Under the Curve* - AUC) . . . 37
3.5 Detalhamento das Abordagens . . . 37
3.5.1 Abordagem 1: Análise de Desempenho Intra-domínio de Representação (*In-domain Representation*) . . . 37
3.5.2 Abordagem 2: Análise de Generalização Inter-domínio de Representação (*Inter-Domain Representation*) . . . 39
3.5.3 Abordagem 3: Análise de Treinamento Combinado . . . 40
3.6 Metodologia de Treinamento e Validação . . . 41
3.6.1 Estratégia de Particionamento: *Stratified Group K-Fold* . . . 41
3.6.2 Pipeline de Processamento e *Data Augmentation* . . . 42
3.6.3 Configuração Experimental e Hiperparâmetros . . . 43

4 EXPERIMENTOS E RESULTADOS . . . 45
4.1 Resultados e Discussão . . . 45
4.1.1 Análise da Abordagem 1: Intra-Domínio . . . 46
4.1.1.1 Domínio Dermastoscópico . . . 46
4.1.1.2 Domínio Clínico . . . 47
4.1.2 Análise da Abordagem 2: Avaliação Inter-Domínio . . . 48
4.1.2.1 Cenário A: Treino Clínico → Teste Dermatoscópico . . . 48
4.1.2.2 Cenário B: Treino Dermatoscópico → Teste Clínico . . . 49
4.1.3 Análise da Abordagem 3: Treinamento Unificado . . . 50
4.1.3.1 Desempenho no Domínio Dermatoscópico . . . 51
4.1.3.2 Desempenho no Domínio Clínico . . . 51
4.2 Validação Estatística: Teste de Wilcoxon . . . 52
4.2.1 Cenário 1: Diagnóstico Clínico . . . 53
4.2.2 Cenário 2: Diagnóstico Dermatoscópico . . . 53
4.2.3 Cenário 3: O *Gap* de Domínio . . . 54

5 CONSIDERAÇÕES FINAIS . . . 55
5.1 Conclusão . . . 55
5.2 Trabalhos Futuros . . . 55

REFERÊNCIAS . . . 57

1 Introdução

1.1 Motivação e Justificativa

A incidência do câncer de pele tem sido uma preocupação crescente em todo o mundo, consolidando-se como o tipo de tumor mais frequente em muitas populações. No Brasil, por exemplo, o câncer de pele não melanoma representa cerca de 30% de todos os tumores malignos diagnosticados. Dentre os diferentes tipos, o melanoma, apesar de menos comum, correspondendo a aproximadamente 3% dos casos de tumores malignos de pele, é o mais perigoso. Sua alta letalidade está diretamente associada à sua elevada capacidade de provocar metástase, ou seja, de se espalhar para outras partes do corpo, tornando o diagnóstico precoce um fator crucial para o sucesso do tratamento. Essa urgência no tratamento se deve ao fato de que as taxas de sobrevivência em cinco anos para o melanoma caem drasticamente de mais de 99% em estágios iniciais para cerca de 14% (ESTEVA et al., 2017) em estágios avançados. Dessa forma, a identificação e classificação precisas são, portanto, fundamentais para a redução das taxas de morbidade e mortalidade.

Historicamente, o diagnóstico de câncer de pele baseia-se principalmente na avaliação visual, complementada por análise dermatoscópica e biópsia. Embora seja eficaz, esse procedimento depende da experiência e julgamento dos profissionais, o que pode levar a variações diagnósticas e erros devido à subjetividade da interpretação das imagens. Além disso, fatores humanos como fadiga, estresse e questões emocionais podem interferir no resultado do diagnóstico, especialmente na identificação de anomalias em estágios iniciais.

Além disso, um dos maiores desafios se diz respeito á variabilidade das imagens clínicas, como a qualidade, zoom, ângulo e iluminação, dificultando ainda mais a classificação. A interpretação manual de imagens dermatoscópicas, embora tenha aumentado as taxas de sucesso no diagnóstico de câncer de pele de 60% para algo em torno de 75-84% (NASERI; SAFAEI, 2025), permanece desafiadora e demorada, aumentando a possibilidade de erros humanos. A falta de acesso a especialistas e equipamentos especializados, como o dermatoscópio, em regiões periféricas e rurais agrava ainda mais essa situação. Diante desses percalços, a demanda por sistemas de diagnóstico automatizados, capazes de fornecer uma interpretação mais objetiva, eficiente e precisa, torna-se evidente.

Nos últimos anos, a Inteligência Artificial, em particular, as redes neurais profundas e as Redes Neurais Convolucionais (CNNs), surgiram como ferramentas revolucionárias em várias áreas, especialmente na visão computacional. As CNNs, por exemplo, destacam-se por sua capacidade de aprender automaticamente a interpretar imagens. Elas constroem o conhecimento de forma hierárquica, identificando primeiro características simples como

bordas e texturas, e depois as combinando para reconhecer objetos completos, o que dispensa a programação manual e extensiva de regras. Esses algoritmos demonstraram a capacidade de superar o desempenho humano em tarefas visuais complexas. No campo da saúde e imagens biomédicas, essa capacidade é bastante promissora, mostrando-se cada vez mais interessantes e benéficas para lidar com os problemas decorrentes de tecidos cancerígenos como, por exemplo, o melanoma. As redes neurais e algoritmos de Inteligência Artificial têm sido amplamente utilizados para analisar grandes volumes de dados científicos, aprender informações complexas e desenvolver sistemas de reconhecimento em processamento de imagens, análise e classificação de textos, bem como para determinar áreas específicas de doenças em imagens biomédicas, desenvolver sistemas de diagnóstico e classificar e prever doenças.

Estudos têm indicado que modelos de deep learning podem alcançar um desempenho comparável ou até superior ao de dermatologistas certificados na classificação de câncer de pele. Por exemplo, uma CNN específica atingiu resultados equiparáveis aos de 21 dermatologistas em tarefas de classificação binária para carcinomas queratinócitos e melanomas malignos (ESTEVA et al., 2017). Para superar desafios como a falta de grandes datasets balanceados e a complexidade das imagens, pesquisadores têm empregado diversas técnicas: aprendizado por transferência (*transfer learning*) para adaptar modelos pré-treinados a domínios específicos de imagens dermatoscópicas, métodos de *ensemble* para combinar múltiplos classificadores e otimizar o desempenho, e técnicas de aprimoramento de imagem como filtros e estratégias de corte para extração de características. Além disso, a fusão de dados multimodais, que integra informações visuais com dados clínicos do paciente (metadados), tem se mostrado crucial para aprimorar a precisão do diagnóstico, pois os dermatologistas consideram fatores como idade, sexo e histórico de câncer. Estratégias como a aumentação de dados (*data augmentation*) e ponderação de classes (*class weighting*) são amplamente utilizadas para mitigar o desequilíbrio comum em datasets de lesões cutâneas, onde as lesões benignas superam as malignas.

1.2 Hipótese

O processo de definição de diagnósticos clínicos, na área de dermatologia, baseia-se na utilização de dermatoscópios que permitem aos dermatologistas observarem estruturas com maior riqueza de detalhes, possibilitando maiores taxas de acerto na definição manual das lesões de pele. A hipótese deste trabalho é, portanto, que a utilização de imagens dermatoscópicas, associadas ou não a bases clínicas no processo de generalização de modelos de *machine learning*, pode impactar positivamente na correta definição automática das mesmas lesões, de modo que a prática humana dos especialistas é replicada no processo de *fine-tuning* dos modelos, que posteriormente podem ser validados tanto em imagens clínicas quanto dermatoscópicas. Por fim, a avaliação desta hipótese pode ser feita de

diversas formas, verificando se conjuntos de imagens dermatoscópicas podem impactar de forma promissora na generalização de lesões de pele utilizando inteligência artificial para posterior validação nas mesmas ou em outras modalidades de descrição das lesões.

1.3 Objetivo

Este trabalho busca avançar no campo do diagnóstico de câncer de pele utilizando abordagens de *deep learning*. A pesquisa divide-se em três frentes principais: inicialmente, modelos são treinados utilizando separadamente imagens dermatoscópicas e imagens clínicas para analisar suas respectivas performances e identificar a eficácia de cada modalidade. Em seguida, avalia-se a capacidade de generalização dos modelos, por meio do treinamento em um tipo de imagem (clínica ou dermatoscópica) e avaliando-os no outro, o que nos possibilita a compreensão da robustez e adaptabilidade das arquiteturas propostas em diferentes cenários clínicos. Por fim, explora-se a combinação das imagens dermatoscópicas e clínicas no treinamento, utilizando apenas uma dessas categorias de imagens para fazer a validação do modelo estudado.

2 Referencial Teórico e Tecnologias Utilizadas

Este capítulo apresenta a fundamentação teórica que serve de base para o desenvolvimento deste trabalho. A sua estrutura foi organizada para fornecer tanto o contexto científico quanto o embasamento técnico necessário para a compreensão da pesquisa. Inicialmente, será realizado um aprofundamento nos conceitos tecnológicos, seguindo uma progressão que parte da definição de Inteligência Artificial, passa pelo subcampo do Aprendizado de Máquina e termina nas arquiteturas de redes neurais profundas. Serão detalhados os mecanismos das Redes Neurais Convolucionais (CNNs), baseadas em transformações por convoluções, e dos *Vision Transformers* (ViT), uma abordagem mais recente baseada em mecanismos de atenção. O objetivo é, portanto, prover o conhecimento necessário para compreender as escolhas metodológicas, os experimentos e a análise dos resultados que serão apresentados nos capítulos subsequentes.

Após o embasamento teórico, a Seção 2.5 passa a detalhar as ferramentas utilizadas neste trabalho, com foco nas tecnologias essenciais para a construção de um modelo robusto em Inteligência Artificial. Por fim, a Seção 2.6 conclui o capítulo, apresentando uma revisão bibliográfica que situa esta pesquisa no panorama dos avanços mais recentes na área.

2.1 Inteligência Artificial e Aprendizado de Máquina

A Inteligência Artificial (IA) é um vasto campo da ciência da computação dedicado à criação de sistemas capazes de realizar tarefas que, tradicionalmente, exigiriam inteligência humana. No campo da saúde, a IA surge como uma resposta direta às limitações dos métodos diagnósticos convencionais. Historicamente, o diagnóstico de câncer de pele depende da avaliação visual de especialistas, um processo sujeito a variações, subjetividade e fatores humanos como estresse e fadiga (Souza Jr. et al., 2024). Essa dependência gerou a demanda por sistemas de diagnóstico automatizados que possam oferecer uma interpretação mais objetiva, eficiente e precisa, auxiliando os especialistas nesta tarefa de definição das lesões.

Neste cenário, a Inteligência Artificial, especialmente através das redes neurais profundas, emergiu como uma ferramenta revolucionária, sobretudo na área de visão computacional. Algoritmos de IA são amplamente utilizados para analisar grandes volumes de dados, aprender informações complexas e desenvolver sistemas de reconhecimento capazes de classificar e prever doenças a partir de imagens biomédicas. (ESTEVA et al., 2017)

2.1.1 Aprendizado de Máquina como um subcampo da IA

O Aprendizado de Máquina, ou Machine Learning, é o subcampo da Inteligência Artificial que confere aos computadores a habilidade de aprender sem serem explicitamente programados. A principal mudança de paradigma está em como a lógica é construída: em vez de um programador definir manualmente um grande conjunto de regras para interpretar uma imagem, os algoritmos de aprendizado de máquina são capazes de aprender essas regras de forma automática, diretamente a partir dos dados.

Essa capacidade permite que os modelos identifiquem padrões e aprendam informações extremamente complexas de forma hierárquica. No contexto da análise de imagens, um modelo pode aprender a reconhecer primeiro características simples, como bordas e texturas, para depois combiná-las e identificar objetos completos, como uma lesão de pele maligna (KRIZHEVSKY; SUTSKEVER; HINTON, 2012).

2.1.2 Tipos de Aprendizado: Supervisionado, Não Supervisionado e por Reforço

O Aprendizado de Máquina pode ser categorizado em três tipos principais, definidos pela natureza dos dados e pelo método de treinamento:

- Aprendizado Supervisionado: Nesta abordagem, o algoritmo é treinado com um conjunto de dados previamente rotulado, ou seja, cada amostra de entrada possui sua saída correta correspondente. Um exemplo prático é treinar um modelo utilizando os pixels de uma imagem e o rótulo da doença como entrada. O objetivo é que o modelo aprenda a mapear as entradas para as saídas corretas e, posteriormente, generalize esse conhecimento para classificar novos dados nunca antes vistos. Este é o tipo de aprendizado utilizado neste trabalho para a classificação de lesões de pele.
- Aprendizado Não Supervisionado: Neste caso, o algoritmo recebe dados sem nenhum rótulo e sua tarefa é encontrar estruturas ou padrões por conta própria, como agrupar lesões com características visuais semelhantes, por exemplo.
- Aprendizado por Reforço: Neste modelo, um agente aprende a tomar decisões através de tentativa e erro, recebendo recompensas por ações corretas e penalidades por ações incorretas, a fim de maximizar uma recompensa total ao longo do tempo.

2.2 Redes Neurais e Aprendizado Profundo (*Deep Learning*)

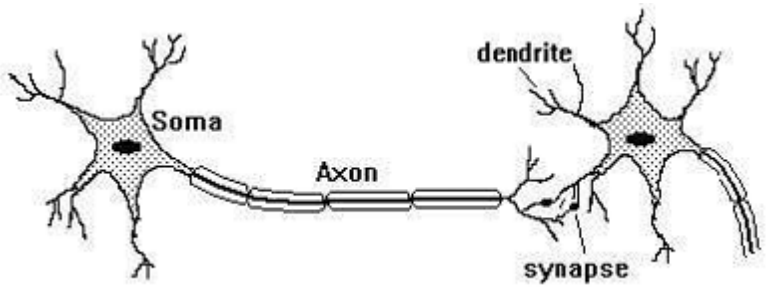
O Aprendizado Profundo, ou Deep Learning, é um subcampo do Aprendizado de Máquina que utiliza Redes Neurais Artificiais (RNAs) com múltiplas camadas para aprender representações de dados de forma hierárquica e progressivamente mais complexa.

É a tecnologia central por trás dos avanços mais significativos em áreas como visão computacional e processamento de linguagem natural.

2.2.1 O Neurônio Artificial: Perceptron

A unidade fundamental de uma rede neural é o neurônio artificial, cujo modelo mais simples é o Perceptron. Inspirado no neurônio biológico, o Perceptron recebe um ou mais sinais de entrada. Esses pesos determinam a importância de cada entrada no processo de decisão. O neurônio calcula a soma ponderada de suas entradas e, em seguida, aplica uma função de ativação para produzir um sinal de saída. Em sua forma original, essa função era um degrau (*step function*) que disparava um sinal (1) se a soma ponderada ultrapassasse um certo limiar, e não disparava (0) caso contrário. Embora um único Perceptron seja limitado a resolver problemas linearmente separáveis, sua força reside na sua utilização como bloco de construção para redes muito mais complexas (ROSENBLATT, 1958).

Figura 1 – Estrutura de um neurônio biológico.



Fonte: (ROSENBLATT, 1958).

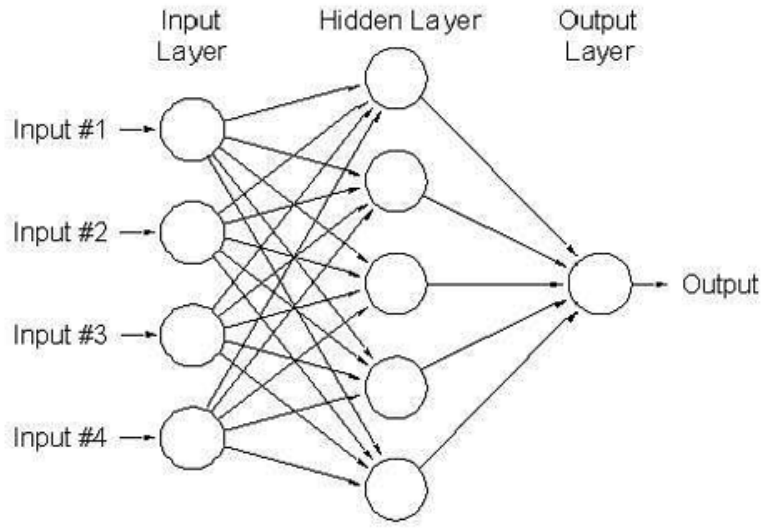
2.2.2 Arquitetura de Redes Neurais: Camadas e Funções de Ativação

Uma Rede Neural Artificial é formada pela interconexão de múltiplos neurônios organizados em camadas sequenciais. Uma arquitetura típica é composta por três tipos de camadas (2) : Camada de Entrada (*Input Layer*), que possui a função de receber os dados brutos. No contexto computacional, cada neurônio nesta camada pode corresponder a um pixel de uma imagem. Após essa camada inicial, temos as Camadas Ocultas (*Hidden Layers*), que fazem a transição entre a entrada e a saída. É nelas que a maior parte do processamento e da extração de características abstratas ocorre. Redes com múltiplas camadas ocultas são o que define o Aprendizado Profundo (Deep Learning). Por fim, a Camada de Saída (*Output Layer*) produz o resultado final da rede. O número de neurônios nesta camada e sua função de ativação dependem da tarefa. Para um problema de classificação com múltiplas classes, como o deste trabalho, a camada de saída geralmente possui um neurônio para cada classe (ZHANG et al., 2023).

As funções de ativação são um componente crucial, pois introduzem não-linearidade

no sistema, permitindo que a rede aprenda relações complexas entre os dados. Sem elas, mesmo uma rede com muitas camadas se comportaria como um simples modelo linear.

Figura 2 – Rede Neural Simples



Fonte: (ZHANG et al., 2023).

2.2.3 O Processo de Treinamento: Backpropagation e Otimizadores

O treinamento de uma rede neural é o processo de ajustar seus pesos para que ela possa mapear corretamente as entradas às saídas desejadas. Esse processo é iterativo e orientado pela minimização de uma função de perda (*loss function*), que quantifica a discrepância entre a predição do modelo e o valor real (rótulo). O algoritmo central para o treinamento é o *Backpropagation* (retropropagação) (ZHANG et al., 2023) funciona em duas fases:

1. *Forward Pass*: Os dados de entrada percorrem a rede, da primeira à última camada, gerando uma predição.

2. *Backward Pass*: O erro calculado pela função de perda é propagado de trás para frente, da camada de saída até a de entrada. Durante essa propagação, o algoritmo calcula o gradiente do erro em relação a cada peso da rede. Esse gradiente indica a direção e a magnitude do ajuste necessário em cada peso para reduzir o erro geral.

Os Otimizadores são os algoritmos que utilizam esses gradientes para efetivamente atualizar os pesos da rede. O método fundamental é o Gradiente Descendente (*Gradient Descent*), que ajusta os pesos na direção oposta ao gradiente. Variações mais avançadas e amplamente utilizadas, como o *Adam*, adaptam a taxa de aprendizado para cada

peso individualmente, resultando em uma convergência mais rápida e estável durante o treinamento (ZHANG et al., 2023).

2.3 Redes Neurais Convolucionais (CNNs)

As Redes Neurais Convolucionais, ou CNNs, são uma classe de redes neurais profundas que se tornaram as ferramentas mais revolucionárias e eficazes no campo da visão computacional. Diferentemente das redes neurais tradicionais, sua arquitetura é especificamente projetada para processar dados com uma topologia de grade, como imagens. A principal vantagem das CNNs é sua notável capacidade de aprender a interpretar imagens de forma automática.

2.3.1 A Operação de Convolução para Extração de Características

O elemento central de uma CNN é a camada convolucional, que realiza a operação de convolução. Esse processo consiste em deslizar um filtro (*kernel*), que é uma pequena matriz de pesos, por toda a imagem de entrada. O objetivo desse filtro é detectar características específicas, como bordas, cantos, texturas ou padrões de cores. O resultado da operação é um *feature map* (mapa de características) que indica as áreas da imagem onde a respectiva característica foi encontrada (LECUN et al., 1998).

A vantagem das CNNs reside em sua capacidade de construir conhecimento de forma hierárquica. As primeiras camadas da rede aprendem a detectar características muito simples, como linhas e cores. As camadas subsequentes recebem os mapas de características das camadas anteriores e os combinam para aprender a reconhecer padrões mais complexos, como formas, olhos ou texturas de pele, até que as camadas mais profundas consigam identificar objetos completos (KRIZHEVSKY; SUTSKEVER; HINTON, 2012). É importante notar que os pesos desses filtros não são pré-definidos; eles são os parâmetros que a rede aprende durante o processo de treinamento .

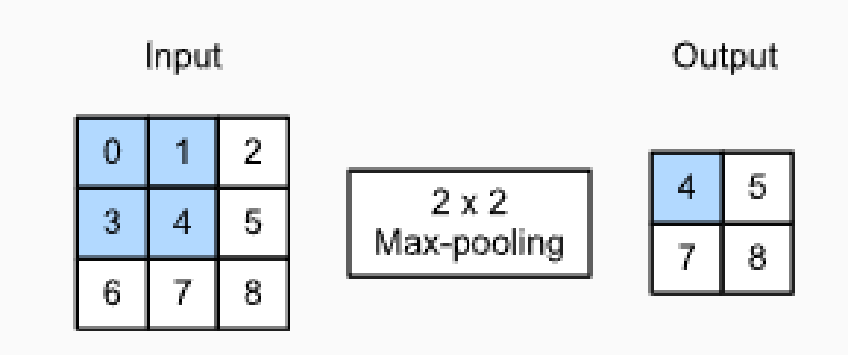
2.3.2 Camadas de Agrupamento (*Pooling*)

Após a extração de características pelas camadas convolucionais, é comum a aplicação de uma camada de agrupamento, ou *pooling*. A principal função desta camada é reduzir progressivamente as dimensões espaciais (largura e altura) dos mapas de características, o que acarreta duas vantagens principais: Redução do número de parâmetros e da carga computacional na rede e criação de uma representação mais robusta, tornando o modelo menos sensível a pequenas distorções na posição das características na imagem (LECUN et al., 1998; KRIZHEVSKY; SUTSKEVER; HINTON, 2012).

A técnica de *pooling* mais comum é o *Max Pooling*, que divide o mapa de caracte-

rísticas em pequenas regiões e, para cada uma delas, seleciona apenas o valor máximo, descartando os demais.

Figura 3 – Max Pooling



Fonte: (ZHANG et al., 2023).

2.3.3 Aprendizagem por Transferência e Ajuste Fino (*Fine-Tuning*)

Treinar uma rede neural profunda do zero exige uma quantidade massiva de dados e um custo computacional muito elevado. Por essa razão, a abordagem dominante na prática é a Aprendizagem por Transferência (*Transfer Learning*), uma estratégia na qual um modelo, já pré-treinado em um *dataset* de larga escala e de propósito geral (como o ImageNet), tem seu conhecimento reaproveitado para uma nova tarefa, geralmente mais específica. Esta abordagem permite alcançar bons resultados mesmo em tarefas com conjuntos de dados menores, como os de imagens médicas, que seriam insuficientes para treinar um modelo profundo a partir de pesos aleatórios.

O principal mecanismo para realizar a aprendizagem por transferênica é o Ajuste Fino (*Fine-Tuning*). O processo consiste em pegar a arquitetura e os pesos do modelo pré-treinado e continuar seu treinamento em um novo dataset (chamado de tarefa *downstream*). O objetivo é adaptar as características visuais genéricas aprendidas durante o pré-treinamento (como bordas, texturas e formas) para as particularidades do novo domínio de dados (YOSINSKI et al., 2014).

Na prática, o ajuste fino geralmente segue dois passos. Primeiro, a camada de classificação final do modelo pré-treinado (por exemplo, a camada que classifica as 1000 classes do ImageNet) é removida e substituída por uma nova camada, inicializada aleatoriamente, com o número de saídas correspondente às classes da nova tarefa. Em seguida, o treinamento é retomado no novo *dataset*, onde existem duas estratégias principais:

- **Congelamento de Camadas:** Apenas os pesos da nova camada de classificação são treinados, enquanto os pesos das camadas anteriores permanecem “congelados“. Esta abordagem é mais rápida e útil quando o novo dataset é pequeno.

- **Ajuste Fino de Todas as Camadas:** A abordagem mais comum é permitir que os pesos de todas as camadas da rede sejam atualizados durante o treinamento no novo *dataset*, geralmente utilizando uma taxa de aprendizado bem menor que a do treinamento inicial. Isso permite que todo o modelo se adapte sutilmente à nova distribuição de dados, resultando em maior performance.

A principal vantagem da transferência de aprendizado é a drástica redução do tempo e dos recursos computacionais necessários para o treinamento, além de possibilitar a obtenção de resultados de ponta em tarefas com dados limitados.

2.3.4 Arquiteturas Clássicas

Desde a popularização do *Deep Learning*, diversas arquiteturas de CNNs se tornaram marcos na evolução da visão computacional, cada uma introduzindo conceitos que refinaram e potencializaram a capacidade desses modelos. A seguir, são descritas algumas das mais influentes.

- **LeNet-5:** Desenvolvida por Yann LeCun, é frequentemente considerada a arquitetura pioneira. Seu sucesso na tarefa de reconhecimento de dígitos manuscritos estabeleceu a sequência fundamental que se tornaria padrão em muitas CNNs: uma sucessão de camadas convolucionais e de *pooling* para extração de características, seguida por camadas totalmente conectadas para a classificação (LECUN et al., 1998).

- **AlexNet:** Esta arquitetura foi a grande responsável por iniciar a revolução do *Deep Learning*, ao vencer com uma margem esmagadora a competição ImageNet (ILSVRC) em 2012. Ela demonstrou que redes muito mais profundas eram viáveis, popularizou o uso da função de ativação ReLU para acelerar o treinamento e provou a eficácia do uso de GPUs para treinar modelos em larga escala (KRIZHEVSKY; SUTSKEVER; HINTON, 2012).

- **VGGNet:** A principal contribuição da VGGNet foi demonstrar o valor da profundidade de forma sistemática. Sua arquitetura é notavelmente simples e uniforme, utilizando exclusivamente filtros convolucionais muito pequenos (3x3) empilhados em sequência para alcançar uma profundidade de até 19 camadas, reforçando a ideia de que redes mais profundas podem alcançar um desempenho superior (SIMONYAN; ZISSERMAN, 2015).

- **GoogLeNet (Inception):** Em vez de apenas empilhar mais camadas, a GoogLeNet introduziu o "módulo Inception". A revolução aqui foi a ideia de executar múltiplas operações de convolução com filtros de diferentes tamanhos (1x1, 3x3, 5x5) em paralelo dentro do mesmo bloco. Isso permitiu que a rede capturasse caracterís-

ticas em diferentes escalas simultaneamente, otimizando a utilização dos recursos computacionais (SZEGEDY et al., 2015).

- **ResNet (Residual Network):** A ResNet resolveu o problema da degradação de performance que ocorria em redes excessivamente profundas. Ela introduziu as "conexões residuais" ou *skip connections*, que criam um atalho para o fluxo do gradiente, facilitando o treinamento de redes com centenas ou até milhares de camadas e permitindo ganhos de acurácia com o aumento da profundidade (HE et al., 2016).

2.4 *Vision Transformers* (ViT)

A arquitetura *Transformer* representa uma quebra de paradigma nos modelos de aprendizado de sequência, introduzindo uma estrutura baseada exclusivamente em mecanismos de atenção que dispensa por completo o uso de camadas recorrentes ou convolucionais. Embora tenha sido originalmente desenvolvida para tarefas de Processamento de Linguagem Natural, sua alta escalabilidade e eficiência inspiraram sua adaptação para a área de visão computacional (VASWANI et al., 2017). Esta seção detalha primeiramente a estrutura e o mecanismo de atenção do *Transformer* original e, em seguida, explica como ele foi modificado para dar origem ao *Vision Transformer* (ViT).

2.4.1 A Arquitetura Transformer e o Mecanismo de Atenção

O coração do *Transformer* é o mecanismo de atenção, mais especificamente o *self-attention* (autoatenção), que permite ao modelo relacionar diferentes posições de uma única sequência para computar uma representação global dela. Uma função de atenção pode ser descrita como um mapeamento que leva uma consulta (*query*), um conjunto de chaves (*keys*) e um conjunto de valores (*values*) a uma saída. A saída é calculada como uma soma ponderada dos valores, onde o peso de cada valor é determinado pela compatibilidade da consulta com a chave correspondente.

A implementação específica proposta foi a **Scaled Dot-Product Attention**. Nela, a compatibilidade é calculada pelo produto escalar entre a consulta (Q) e a chave (K). Para evitar que o resultado do produto escalar cresça excessivamente e sature a função Softmax, é aplicado um fator de escala (VASWANI et al., 2017). A fórmula é definida como:

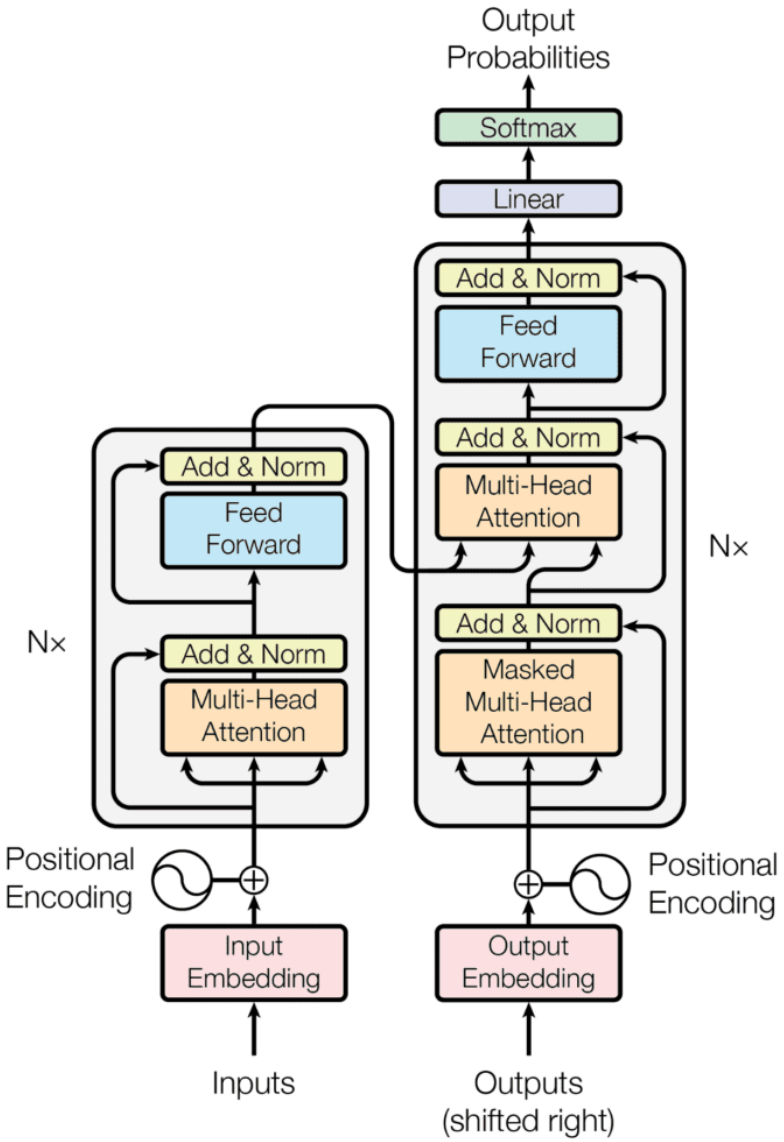
$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.1}$$

onde d_k é a dimensão dos vetores de chave e consulta.

Para aprimorar este mecanismo, foi introduzido o *Multi-Head Attention*. Em vez de realizar uma única função de atenção, o modelo projeta linearmente as consultas,

chaves e valores h vezes em paralelo para dimensões menores. O mecanismo de atenção é aplicado a cada uma dessas projeções ("cabeças") de forma independente. Os resultados de cada cabeça são então concatenados e projetados novamente para gerar a saída final. A grande vantagem dessa abordagem é que ela permite ao modelo atender conjuntamente a informações de diferentes subespaços de representação e em diferentes posições.

Figura 4 – Transformer : Arquitetura do Modelo



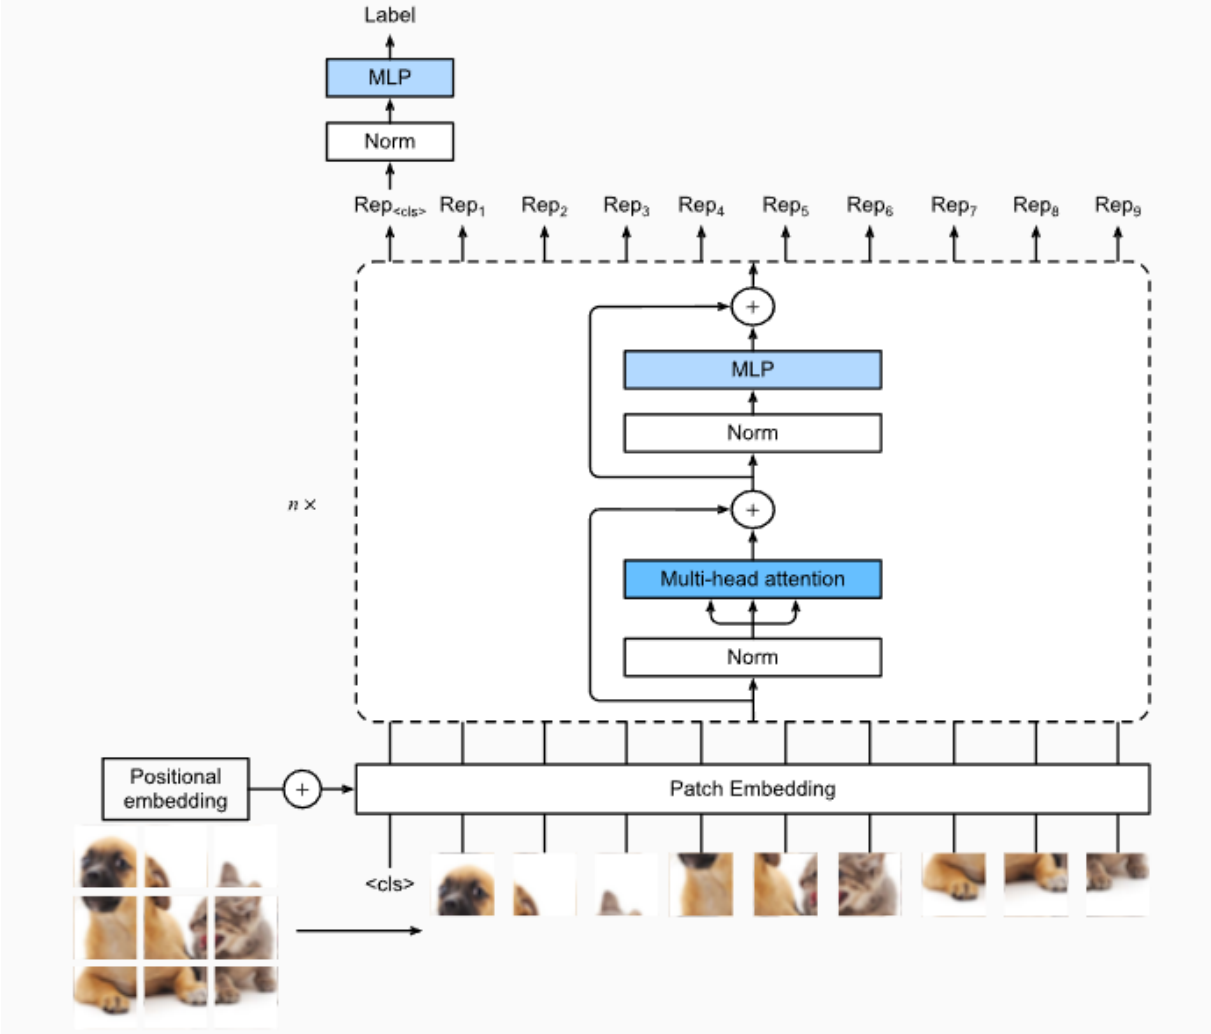
Fonte: (VASWANI et al., 2017).

2.4.2 A Adaptação para Visão Computacional: O Vision Transformer (ViT)

A adaptação da poderosa arquitetura Transformer para o domínio da visão computacional deu origem ao Vision Transformer (ViT). Como o modelo original foi projetado para operar sobre sequências unidimensionais de *tokens*, a principal inovação do ViT foi

criar um método para converter uma imagem bidimensional em uma sequência.

Figura 5 – Arquitetura do Vision Transformer



Fonte: (ZHANG et al., 2023).

A abordagem consiste em dividir a imagem em uma grade de *patches* (pequenos recortes) de tamanho fixo. Cada *patch* é então "achatado" (transformado em um vetor) e passa por uma projeção linear, gerando uma sequência de vetores de tamanho uniforme. Essencialmente, os *patches* da imagem são tratados de forma análoga aos *tokens* (palavras) de uma sentença. Para que o modelo mantenha a informação espacial original, "*embeddings* de posição" são somados aos vetores de cada *patch*. A sequência resultante de vetores é, então, fornecida como entrada para um codificador *Transformer* padrão, que processará a imagem levando em consideração questões de posicionamento e tokenização presentes nas abordagens aplicadas aos problemas de processamento de linguagem natural que utilizam esta tecnologia. (DOSOVITSKIY et al., 2021).

2.5 Ferramentas Utilizadas

A execução deste trabalho, desde o pré-processamento dos dados até o treinamento e a avaliação dos modelos, foi viabilizada por um conjunto de ferramentas consolidadas no ecossistema de IA. Esta seção descreve as tecnologias implementadas durante a pesquisa.

A linguagem de programação escolhida foi o *Python*, devido à sua robustez, simplicidade e ao vasto suporte de bibliotecas para computação científica e *deep learning*. As principais bibliotecas utilizadas foram:

- **PyTorch:** Será utilizado como o principal *framework* para a construção e o treinamento das redes neurais profundas. Oferece um alto nível de abstração, suporte para diferenciação automática (essencial para o *backpropagation*) e otimizações para execução em GPUs.
- **Scikit-learn:** Ferramenta essencial para a etapa de avaliação dos modelos. Pode ser utilizada para o cálculo das métricas de desempenho, como Acurácia, Acurácia Balanceada e AUC, além da geração de matrizes de confusão.
- **NumPy e Pandas:** NumPy é a base para todas as operações numéricas e manipulação de arrays multidimensionais. Pandas é fundamental para a leitura, limpeza e análise dos metadados associados aos datasets de lesões de pele.
- **Matplotlib e Seaborn:** Utilizadas para a visualização dos resultados, permitindo a criação de gráficos de curvas de treinamento, histogramas de distribuição de classes e outras representações visuais para a análise comparativa dos modelos.
- **OpenCV e Pillow (PIL):** Serão empregadas no pré-processamento das imagens, realizando tarefas como leitura, redimensionamento, recortes e a aplicação de técnicas de aumento de dados (*data augmentation*).

2.6 Trabalhos Correlatos

Uma das grandes ferramentas utilizadas nesse estudo é o *dataset* PAD-UFES-20 (PACHECO et al., 2020), desenvolvido por pesquisadores da UFES, cuja principal contribuição é ser o primeiro arquivo público a disponibilizar imagens clínicas de lesões de pele coletadas por smartphones, juntamente com dados detalhados dos pacientes. Ele preenche uma lacuna na pesquisa, que até então focava em imagens de dermatoscopia, dependentes de equipamentos caros e pouco acessíveis. A disponibilização deste acervo visa impulsionar o desenvolvimento de sistemas de Diagnóstico Auxiliado por Computador (CAD) de baixo custo, ideais para uso em áreas rurais e remotas. O trabalho também contribui ao permitir pesquisas sobre a relação entre dados clínicos e de imagem para

aprimorar a detecção do câncer de pele. A alta confiabilidade do *dataset* é uma contribuição chave, com 100% dos diagnósticos de câncer sendo confirmados por biópsia.

O trabalho realizado por Souza Jr. et al. (2024) introduziu o modelo LiwTERM, um modelo leve baseado em transformers para classificar lesões de pele usando imagens e dados clínicos. A metodologia envolve extrair *features* de imagens com um *Vision Transformer* (ViT) pré-treinado e de texto clínico com um Modelo de Linguagem (*Language Model* - LM) também pré-treinado, combinando-as em um "*shallow light weight model*" (SLM) que é, por sua vez, ajustado. O estudo utilizou duas bases de dados públicas: PAD-UFES-20 e ISIC 2019. As métricas de avaliação incluíram Sensibilidade (S), Especificidade (P) e Acurácia Balanceada (BACC). Os resultados indicaram que o LiwTERM alcançou desempenho competitivo, especialmente quando combinando *features* de imagem e texto, superaram abordagens que usam apenas uma modalidade. A principal contribuição é um modelo leve (em comparação a outras arquiteturas baseadas em *Transformers*) e eficiente para detecção multimodal de lesões dermatológicas, adequado para cenários com recursos computacionais limitados, sem a necessidade de treinar arquiteturas profundas extensivamente. O LiwTERM demonstrou ser adaptável mesmo com informações clínicas incompletas.

Já o estudo conduzido por Pacheco e Krohling (2021) propôs o método *Metadata Processing Block* (MetaBlock), um mecanismo baseado em atenção projetado para aprimorar a classificação de câncer de pele ao combinar imagens e metadados em modelos de aprendizado profundo. A metodologia central do MetaBlock utiliza os metadados do paciente para realçar dinamicamente as características mais relevantes extraídas das imagens por Redes Neurais Convolucionais (CNNs), permitindo que os metadados guiem a interpretação visual. Testado nos datasets ISIC 2019 e PAD-UFES-20 com métricas como BACC, o MetaBlock demonstrou melhorar a classificação e superar outras abordagens de fusão, especialmente no PAD-UFES-20, que possui mais metadados. O estudo conclui que o MetaBlock é uma contribuição robusta e eficaz para a fusão multimodal de dados no contexto de classificação de lesão de pele, aprimorando a performance da classificação neste contexto. Suas principais contribuições incluem ser um mecanismo de atenção estável, agnóstico à arquitetura da CNN e que adiciona um custo computacional (aumento no número de parâmetros) quase insignificante.

Nawaz et al. (2025) apresentaram uma arquitetura de CNN, chamada FCDS-CNN, projetada especificamente para a detecção e classificação de câncer de pele a partir de imagens dermatoscópicas. Foi utilizado um dataset público da plataforma *Kaggle* que continha 10.015 imagens dermatoscópicas, divididas em sete classes de lesões de pele, ceratoses actínias (AK), carcinomas basocelulares (BCC), ceratoses benignas (BKL), dermatofibromas (DF), nevos melanocíticos (NV), melanomas (MEL) e lesões vasculares (VASC). O principal objetivo foi desenvolver um modelo que lidasse com os desafios

específicos de datasets médicos, como o desbalanceamento de classes e a alta similaridade entre esses tipos de lesões. Para isso, utilizou-se técnicas de *Data Augmentation*, como aplicações de rotações, *zooms* e inversões nas imagens para aumentar a variedade do dataset. Além disso, foi aplicado o *Class Weighting* (Ponderação de Classes), onde é atribuído um peso maior ás classes que possuem menos dados durante o treinamento, forçando o modelo a prestar atenção aos exemplos menos comuns. O modelo FCDS-CNN , em relação aos outros modelos, demonstrou superioridade em todas as métricas de avaliação, incluindo Acurácia, Precisão, Recall, F1-Score e *Area Under Curve* (AUC).

Em seu estudo, Esteva et al. (2017) demonstraram que uma única rede neural convolucional (CNN) é capaz de classificar o câncer de pele com um nível de competência comparável ao de dermatologistas certificados. Para isso, utilizaram uma arquitetura GoogleNet Inception v3 pré-treinada na base de dados ImageNet, aplicando transfer learning em um massivo conjunto de dados próprio com 129.450 imagens clínicas, abrangendo 2.032 doenças diferentes. O treinamento foi realizado de ponta a ponta (*end-to-end*), utilizando apenas os pixels das imagens e os rótulos das doenças como entrada. O desempenho do modelo foi validado em comparação a 21 dermatologistas em cenários críticos de classificação binária: carcinomas queratinocíticos versus queratoses seborreicas, e melanomas malignos versus nevos benignos, utilizando imagens confirmadas por biópsia. O modelo alcançou uma performance no mesmo nível dos especialistas, com uma Área Sob a Curva (AUC) superior a 0,91 em todos os casos de teste. A principal contribuição do trabalho foi demonstrar a viabilidade de um sistema de inteligência artificial para triagem dermatológica, com potencial para ampliar o acesso a diagnósticos de baixo custo através de dispositivos móveis.

Em seu trabalho, K. et al. (2021) propuseram uma abordagem de classificação multiclasse para lesões de pele, baseada em *Transfer Learning* e uma técnica de *ensemble* chamada *blending*. A metodologia utilizou quatro modelos pré-treinados (DenseNet201, Inception-v3, Inception-ResNet-v2 e Xception) como classificadores base. As predições desses modelos foram combinadas através do *blending*, onde um *meta-learner* (Perceptron de Múltiplas Camadas) foi treinado com as saídas dos modelos base para gerar a classificação final. O estudo, que foi conduzido no *dataset* ISIC 2019, também aplicou uma estratégia de recorte de imagem para padronizar os dados antes do treinamento. Os resultados demonstraram que o modelo de *ensemble* superou o desempenho dos classificadores individuais, alcançando uma acurácia balanceada de 81,2% em um dos subconjuntos de dados compilados. A principal contribuição do trabalho foi a implementação e validação de um sistema de *ensemble* que trata os sub-modelos como uma única rede, aprendendo assim a melhor forma de combinar suas predições para aprimorar a precisão do diagnóstico.

O estudo de Dandu, Murthy e Kumar (2023) propôs uma abordagem de classificação híbrida para a detecção de melanoma, com o objetivo de identificar a combinação mais

eficiente entre técnicas de extração de características e algoritmos de aprendizado de máquina. Utilizando o dataset de referência SIIM-ISIC. Ao contrário dos modelos de *deep learning* que aprendem características de forma automática, a metodologia de Dandu, Murthy e Kumar (2023) baseia-se na extração explícita de características através de três filtros distintos: *Auto Color Correlogram*, *Binary Patterns Pyramid* e *Colour Layout Filter* (CLF). Essas características foram então submetidas a dois classificadores de *ensemble*: *Bagging* e *Attribute Selected Classifier* (ASC). A pesquisa comparou o desempenho das seis combinações possíveis e concluiu que o modelo que utiliza o *Attribute Selected Classifier* (ASC) em conjunto com o *Colour Layout Filter* (CLF) alcançou o resultado mais otimizado, com uma acurácia alta de 90,96%.

Em um estudo comparativo, M e P (2024) investigaram diferentes estratégias de ajuste fino (*fine-tuning*) para a classificação de lesões de pele. A metodologia partiu do pré-processamento do dataset HAM10000, que incluiu o redimensionamento das imagens e a aplicação de aumento de dados (*data augmentation*), especificamente a técnica de *Horizontal Flip*, para lidar com o desequilíbrio entre as classes. O trabalho se distingue por avaliar e comparar explicitamente dois cenários de treinamento em modelos como VGG16, Inception V3 e DenseNet201. Para o primeiro, foi feito o ajuste fino apenas das camadas superiores, realizado por cerca de 30 épocas, já no segundo caso, houve o ajuste fino de todas as camadas do modelo, que necessitou de apenas 20 épocas. Após essa análise, os autores criaram um modelo de *ensemble* combinando as melhores versões do Inception V3 e DenseNet201, concluindo que o ajuste fino completo não só gerou maior acurácia (88,52% no teste e 88,8% no conjunto de validação para o *ensemble*), mas também acelerou a convergência do treinamento.

3 Metodologia

3.1 Visão Geral

Esta seção visa detalhar a estrutura metodológica desenhada para investigar a hipótese central deste estudo e alcançar os objetivos propostos. A pesquisa se baseia na premissa de que a utilização de imagens dermatoscópicas no treinamento de modelos de aprendizado profundo pode aprimorar a capacidade de generalização e precisão na classificação automática de lesões de pele em imagens clínicas. Para validar essa ideia, são conduzidos experimentos utilizando diferentes abordagens de treinamento, validação e combinação de dados. O estudo faz uso de duas bases de dados: o ISIC 2019 (International Skin Imaging Collaboration (ISIC), 2019) - um *dataset* de referência composto por imagens dermatoscópicas, permitindo a visualização de lesões com alta riqueza de detalhes - e o PAD-UFES-20+ - uma versão estendida do *dataset* que já foi apresentado neste trabalho, o PAD-UFES-20 (PACHECO et al., 2020), que além de apresentar aproximadamente 6,5× mais amostras clínicas do que o *dataset* original, também apresenta imagens dermatoscópicas das lesões de pele.

Para a tarefa de classificação, foram selecionadas arquiteturas de Redes Neurais Convolucionais (CNNs) e *Vision Transformers* (ViT) amplamente consolidadas no contexto da visão computacional. Os modelos escolhidos incluem ResNet50, ResNet101, MobileNetV3 e ViT. Essa seleção abrange desde modelos consolidados e robustos até arquiteturas mais modernas e eficientes, permitindo uma análise comparativa abrangente.

As próximas seções detalham as especificidades das bases de dados utilizadas, a análise exploratória, as métricas de avaliação que quantificam o desempenho dos modelos e a metodologia detalhada de cada uma das abordagens experimentais.

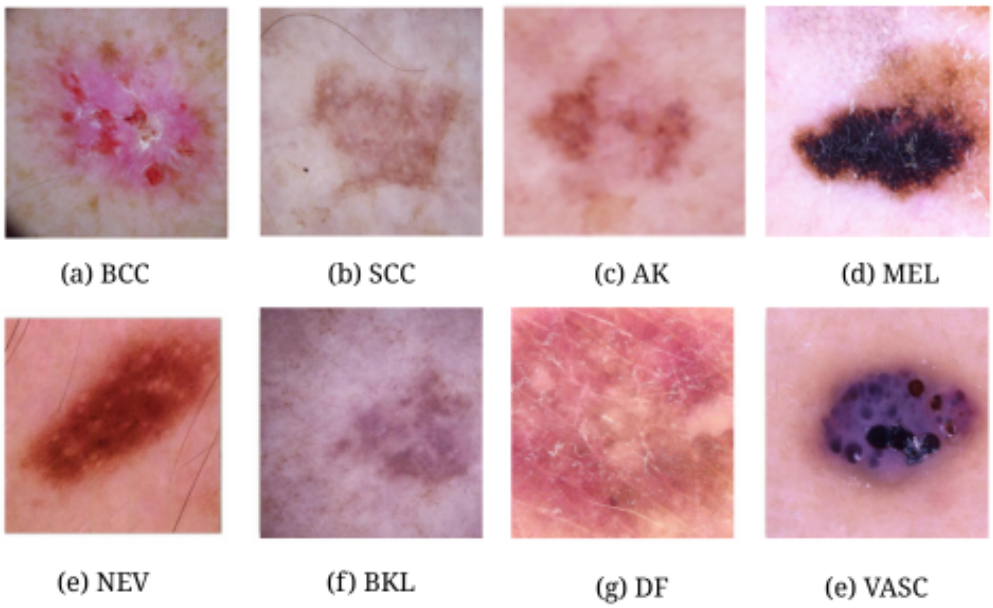
3.2 Bases de Dados e Análise Exploratória

Para a condução dos experimentos, foram selecionadas duas bases de dados que são centrais para a hipótese deste trabalho, distinguindo-se principalmente pela natureza das imagens: uma clínica e outra dermatoscópica. A Análise Exploratória dos Dados focada nos rótulos diagnósticos é uma etapa fundamental para compreender a distribuição das classes, identificar inconsistências e orientar o pré-processamento necessário para o treinamento dos modelos.

3.2.1 ISIC 2019

O ISIC 2019 (International Skin Imaging Collaboration (ISIC), 2019) é composto por 25.331 imagens dermatoscópicas públicas. Tais imagens, obtidas com dermatoscópios, possuem um alto nível de detalhe estrutural, sendo o padrão-ouro para a análise visual por especialistas em dermatologia para diagnósticos clínicos de lesões de pele. O conjunto de metadados associado é menos abrangente, incluindo apenas três características clínicas: idade, sexo e região anatômica da lesão.

Figura 6 – Exemplo de cada lesão de pele presente no *dataset* ISIC19



Fonte: (International Skin Imaging Collaboration (ISIC), 2019).

3.2.1.1 Distribuição de Classes e Desbalanceamento

A análise das *labels* revelou a presença de oito categorias diagnósticas principais, após a remoção da coluna referente a casos desconhecidos (UNK), que não apresentava registros válidos. A distribuição quantitativa observada foi:

- **Nevo Melanocítico (NV):** 12.875 imagens
- **Melanoma (MEL):** 4.522 imagens
- **Carcinoma Basocelular (BCC):** 3.323 imagens

- **Ceratose Benigna (BKL):** 2.624 imagens
- **Ceratose Actínica (AK):** 867 imagens
- **Carcinoma Espinocelular (SCC):** 628 imagens
- **Lesão Vascular (VASC):** 253 imagens
- **Dermatofibroma (DF):** 239 imagens

Os dados evidenciam um forte desbalanceamento de classes, característica comum em bases de dados médicas, onde lesões benignas como o NV representam mais de 50% do total de amostras. Esse fator exige estratégias específicas durante a divisão dos dados para evitar que o modelo se torne tendencioso à classe majoritária. Para assegurar que a avaliação do modelo não seja enviesada por divisões aleatórias que poderiam excluir classes minoritárias dos conjuntos de teste, utiliza-se a estratégia de validação cruzada estratificada (*Stratified K-Fold*). Essa técnica garante que a proporção original de cada diagnóstico seja preservada em todas as sub-divisões (*folds*) do experimento. Dessa forma, assegura-se que o modelo seja treinado e validado consistentemente em todo o espectro de patologias, desde as classes dominantes até as ocorrências mais raras, conferindo maior robustez às métricas de desempenho apresentadas.

3.2.2 PAD-UFES-20+

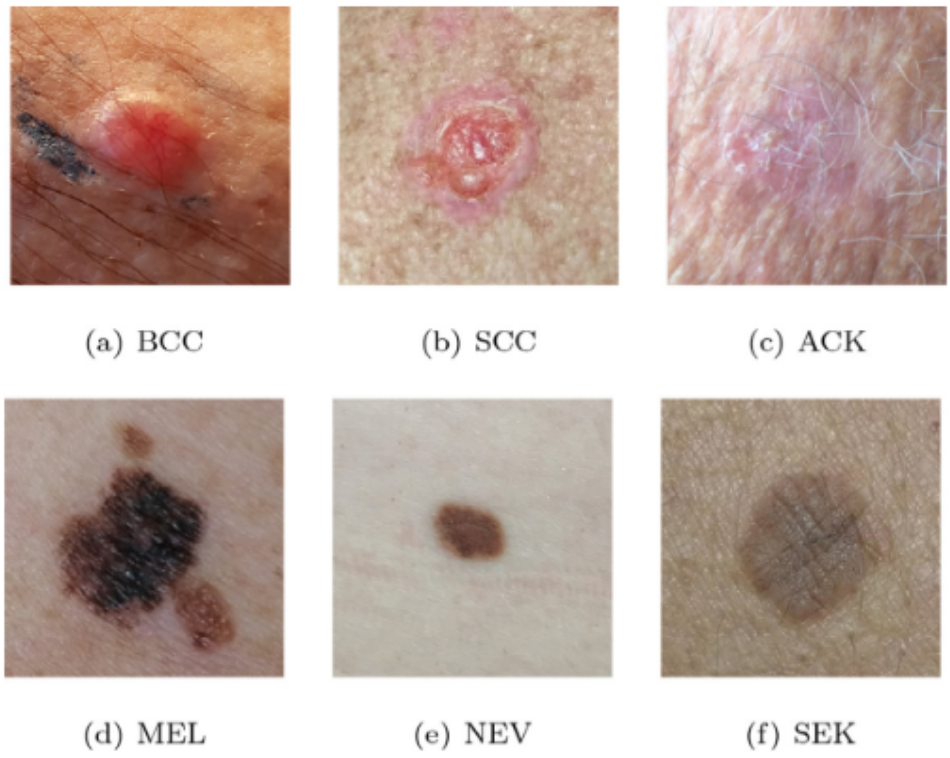
Trata-se de uma versão estendida do PAD-UFES-20 (PACHECO et al., 2020), um *dataset* composto por imagens clínicas de lesões de pele adquiridas no estado do Espírito Santo, Brasil. A versão estendida, denominada PAD-UFES-20+, é aproximadamente 6,5 vezes maior que a original e foi escolhida para avaliar o desempenho dos modelos em um cenário mais próximo da realidade. Ela contém 15.112 amostras de 5.589 pacientes. Uma característica fundamental desse *dataset* é a presença de metadados faltantes numa taxa de aproximadamente 14%, permitindo testar a robustez dos modelos em condições não controladas e com dados incompletos do mundo real.

O *dataset* inclui 21 atributos clínicos dos pacientes e abrange seis classes de lesões de pele. O PAD-UFES-20+ também apresenta, aproximadamente, 3 mil amostras dermatoscópicas (com referenciais clínicos no *dataset* de imagens clínicas), as quais podem ser utilizadas para avaliar as abordagens propostas neste trabalho com relação à transferência de aprendizado.

3.2.2.1 Mapeamento de Classes e Interoperabilidade

A análise inicial do conjunto revelou uma taxonomia médica baseada em códigos da CID-10 e descrições clínicas detalhadas, resultando em mais de 25 subcategorias

Figura 7 – Exemplo de cada lesão de pele presente no *dataset* PAD-UFES-20+



(a) BCC (b) SCC (c) ACK

(d) MEL (e) NEV (f) SEK

Fonte: (PACHECO et al., 2020).

diagnósticas distintas. Para viabilizar a análise comparativa e o treinamento do modelo junto à base do ISIC, foi implementado um script de pré-processamento para padronizar essa diversidade em seis classes-alvo principais.

A estratégia de agregação de classes baseou-se na detecção de *sub-strings* dos códigos CID-10 dentro da coluna `clinicalDiagnostic`, conforme a seguinte lógica:

- **MEL (Melanoma):** Consolida o Melanoma Maligno (C43) e o Lentigo Maligno (D03), tratando-os como uma classe unificada de lesões melanocíticas malignas.
- **NV (Nevo):** Reúne os Nevos Melanocíticos (D22) e Nevos não-neoplásicos (L78), seguindo o padrão de nomenclatura do ISIC para lesões benignas.
- **BCC (Carcinoma Basocelular):** Mapeia o código C80, que representa a neoplasia maligna mais frequente no conjunto de dados após o processamento.
- **SCC (Carcinoma Espinocelular):** Agrupa o Carcinoma Espinocelular (C44) e a Doença de Bowen (D04), garantindo que lesões com potencial invasivo similar e carcinomas *in situ* sejam tratados conjuntamente.
- **AK (Ceratose Actínica):** Isola as lesões pré-malignas associadas ao código L57, de alta relevância clínica pelo risco de evolução para SCC.

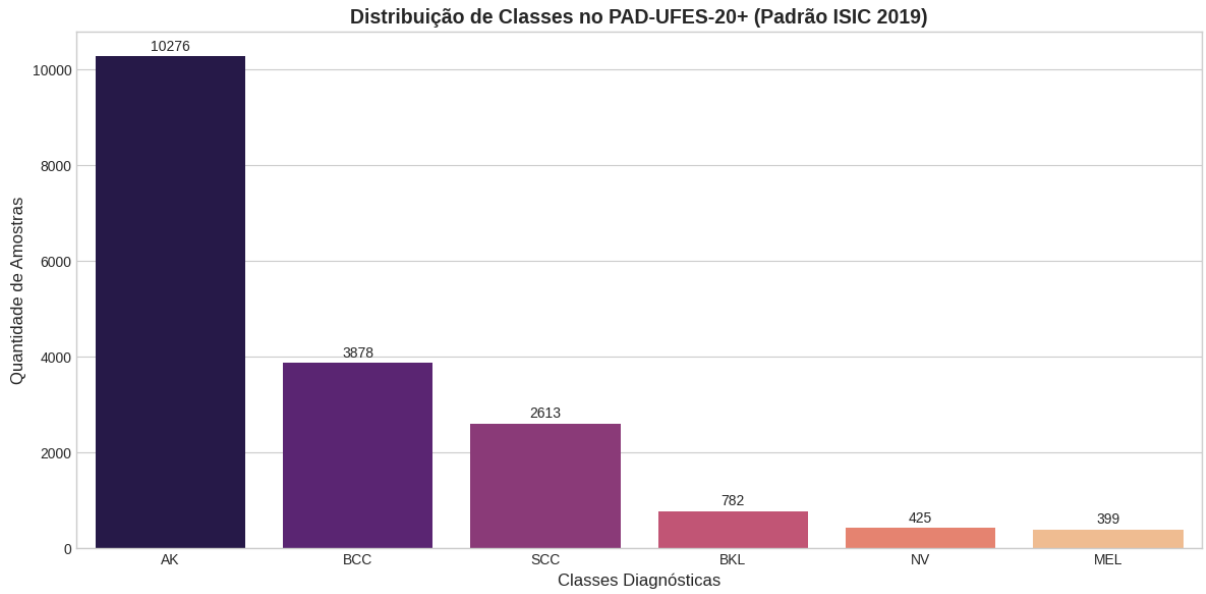
- **BKL (Benign Keratosis-like):** Mapeia a Ceratose Seborreica (L82), permitindo a comparação direta com a classe BKL definida em competições internacionais.

Registros que não apresentaram correspondência com os códigos prioritários (como dermatofibromas ou inflamações inespecíficas) foram marcados como nulos e removidos do conjunto de treinamento, garantindo a integridade do escopo oncológico do modelo.

3.2.2.2 Distribuição e Desbalanceamento

Após a aplicação do mapeamento, a análise da distribuição revelou um desbalanceamento severo (Figura 8). A classe **AK** (Ceratose Actínica) apresenta-se como a classe majoritária com 10.263 amostras (referentes ao código L57.0), superando expressivamente as demais classes, como o **Melanoma (MEL)** e o **Nevo (NV)**, que somam poucas centenas de registros.

Figura 8 – Distribuição de diagnósticos padronizados no *dataset* PAD-UFES-20+.



Fonte: Gerado pelo autor.

Este perfil de distribuição é característico de dados coletados em triagens clínicas reais e impõe a necessidade de técnicas de estratificação rigorosas para as fases de particionamento e validação dos modelos.

3.3 Unificação dos Datasets

A unificação dos conjuntos de dados ISIC 2019 e PAD-UFES-20+, denominado PADISIC+, tem como propósito fundamental a padronização do *dataset* híbrido, assegurando a conformidade das categorias diagnósticas provenientes de diferentes fontes. Este

processo é essencial para garantir que o modelo de aprendizado de máquina processe informações estruturalmente homogêneas, independentemente da origem dos dados. Tal combinação também é possível uma vez que existe uma clara relação entre as bases de dados, tratando-se de imagens dermatoscópicas representadas em ambas. Do ponto de vista do tipo de representação, a base ISIC 2019 está inscrita em PAD-UFES-20+.

3.3.1 Processo de Padronização e Integração

Para viabilizar a concatenação, foi desenvolvido um fluxo de preparação individual para cada fonte, garantindo a paridade entre os atributos fundamentais:

- **Preparação ISIC 2019:** As imagens foram carregadas e rotuladas conforme as oito classes originais do desafio (MEL, NV, BCC, AK, BKL, SCC, DF, VASC), sendo todas categorizadas sob o domínio *DERMATOSCOPE*.
- **Preparação PAD-UFES-20+:** Aplicou-se a função de mapeamento descrita na Seção 3.2.2.1, filtrando apenas os registros que possuíam um *target* válido e preservando a distinção entre imagens clínicas (*CLINICAL*) e dermatoscópicas (*DERMATOSCOPE*).

O processo de *merge* foi feito através da concatenação dos *dataframes* resultantes, totalizando um volume de 43.704 amostras, das quais 18.373 (42%) provêm do PAD-UFES e 25.331 (58%) do ISIC 2019.

3.3.2 Perfil do Dataset Híbrido

A unificação resultou em um aumento expressivo na diversidade de domínios. Embora o PAD-UFES-20+ seja majoritariamente composto por imagens clínicas, ele contribuiu para elevar o volume total de imagens dermatoscópicas para 27.386 amostras, enquanto o domínio clínico consolidou-se com 16.318 amostras.

A Tabela 1 apresenta a distribuição final das classes. É importante notar que, como o *dataset* PAD-UFES-20+ não contempla as categorias de lesões vasculares (VASC) e dermatofibromas (DF), a volumetria destas classes no *dataset* unificado é derivada exclusivamente do ISIC 2019, mantendo-se em 253 e 239 imagens, respectivamente. Dessa forma, espera-se um desempenho inferior das métricas de avaliação para essas classes.

Tabela 1 – Distribuição quantitativa de classes segmentada por tipo de imagem no *dataset* unificado.

Tipo de Imagem	**AK**	**BCC**	**BKL**	**DF**	**MEL**	**NV**	**SCC**	**VASC**	**TOTAL**
CLÍNICA	9.190	3.287	727	0	338	405	2.371	0	16.318
DERMATOSCÓPICA	1.953	3.914	2.679	239	4.583	12.895	870	253	27.386
TOTAL	**11.143**	**7.201**	**3.406**	**239**	**4.921**	**13.300**	**3.241**	**253**	**43.704**

Esta disparidade da quantidade de dados reforça o desbalanceamento inerente ao problema, onde classes como **NV** e **AK** dominam o conjunto, enquanto lesões raras possuem representatividade inferior a 1%.

3.4 Métricas de Avaliação

A seleção de métricas de avaliação adequadas é um passo fundamental para analisar e quantificar o desempenho dos modelos de forma precisa. Em um contexto de diagnóstico médico, onde os dados são frequentemente desbalanceados (com um número muito maior de casos benignos do que malignos), métricas que consideram a performance em cada classe individualmente são cruciais. Dessa forma, este trabalho utiliza um conjunto de três métricas para fornecer uma análise robusta da capacidade de classificação dos modelos.

3.4.1 Acurácia (*Accuracy*)

A acurácia é a métrica mais intuitiva, representando a proporção de predições corretas em relação ao total de amostras. Embora seja uma medida geral de desempenho, ela pode ser enganosa em cenários com classes desbalanceadas. Por exemplo, um modelo que classifica todas as lesões como benignas em um *dataset* com 95% de amostras benignas alcançaria 95% de acurácia, mas seria ineficaz na prática para detectar casos malignos.

Ela é calculada com base nos valores: Verdadeiro Positivo (VP), Verdadeiro Negativo (VN), Falso Positivo (FP) e Falso Negativo (FN).

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} \tag{3.1}$$

3.4.2 Acurácia Balanceada (*Balanced Accuracy* - BACC)

Para contornar a limitação da acurácia padrão, a Acurácia Balanceada (BACC) é utilizada. Esta métrica é especialmente importante para este estudo e é frequentemente empregada em trabalhos que abordam contextos médicos. A BACC calcula o desempenho do modelo em cada classe separadamente e depois calcula a média aritmética destas. Isso penaliza o viés em direção à classe majoritária, exigindo um desempenho equilibrado em todas as classes, e não apenas na majoritária. Em um contexto de classificação binária, ela é definida como a média aritmética da Sensibilidade e da Especificidade.

A Sensibilidade (Recall) é a proporção de casos positivos que foram corretamente previstos, sendo calculada por:

$$Sensibilidade = \frac{VP}{VP + FN} \tag{3.2}$$

A Especificidade, que mede a proporção de casos negativos corretamente identificados, é calculada por:

$$Especificidade = \frac{VN}{VN + FP} \tag{3.3}$$

Dessa forma, é possível calcular a Acurácia Balanceada, conforme Equações 3.2, 3.3, e 3.4:

$$BACC = \frac{Sensibilidade + Especificidade}{2} \tag{3.4}$$

3.4.3 Área Sob a Curva ROC (*Area Under the Curve* - AUC)

A AUC é outra métrica para avaliar classificadores em *datasets* desbalanceados e também é utilizada em estudos de referência na área. Ela representa a área sob a curva ROC (*Receiver Operating Characteristic*), que é um gráfico da Sensibilidade (Equação 3.2) em função dos Falsos Positivos para todos os limiares de classificação possíveis.

O valor da AUC varia de 0 a 1, onde:

- AUC = 1 : Representa um classificador perfeito
- AUC = 0,5: Representa um classificador que não possui capacidade de discriminação melhor que uma escolha aleatória, equivalendo a um palpite estritamente ao acaso.

A principal vantagem da AUC é que ela avalia a qualidade geral do modelo em distinguir entre as classes, fornecendo uma medida de performance mais completa.

3.5 Detalhamento das Abordagens

Para investigar a hipótese de forma sistemática, a metodologia é dividida em três abordagens experimentais diferentes, cada uma projetada para responder a uma questão específica do problema de generalização de domínio. Todas as abordagens utilizam as arquiteturas de modelo selecionadas (ResNet, MobileNet e ViT) e são avaliadas com base no conjunto de métricas definido na Seção 3.4.

3.5.1 Abordagem 1: Análise de Desempenho Intra-domínio de Representação (*In-domain Representation*)

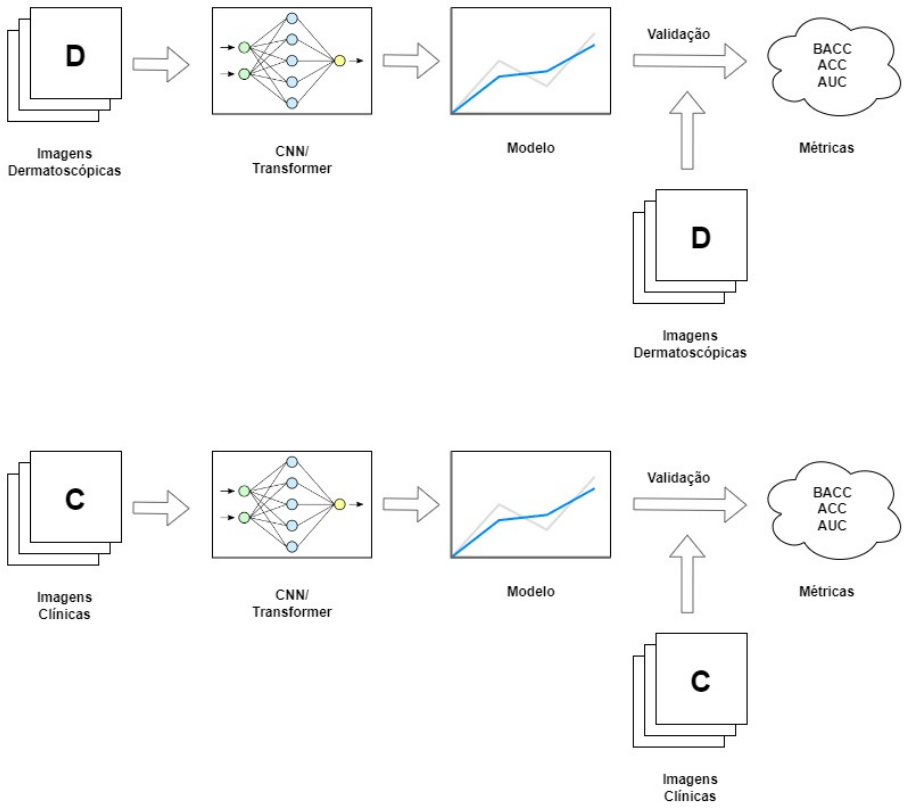
O primeiro passo consiste em estabelecer um *baseline* para o desempenho dos modelos com relação aos domínios de origem das bases de dados. Esta análise é crucial para

criar um ponto de referência que permite medir o impacto das estratégias de generalização subsequentes. São conduzidos dois experimentos principais:

- **Cenário Clínico-para-Clínico:** O modelo é treinado, validado e testado utilizando exclusivamente o conjunto de imagens clínicas do *dataset* PAD-UFES-20+. O objetivo é verificar a performance máxima do modelo quando os dados de treinamento e teste pertencem à mesma distribuição.
- **Cenário Dermatoscópico-para-Dermatoscópico:** De forma análoga, o modelo é treinado, validado e testado utilizando o conjunto consolidado de imagens dermatoscópicas (composto pela união do ISIC 2019 e das imagens dermatoscópicas do PAD-UFES-20+). Este experimento determina o desempenho de referência para o domínio de alta interpretação dermatóscópica das imagens.

Os resultados desta etapa servem como ponto base de performance para cada domínio isoladamente.

Figura 9 – Figura ilustrativa da primeira abordagem.



Fonte: Gerado pelo autor.

3.5.2 Abordagem 2: Análise de Generalização Inter-domínio de Representação (*Inter-Domain Representation*)

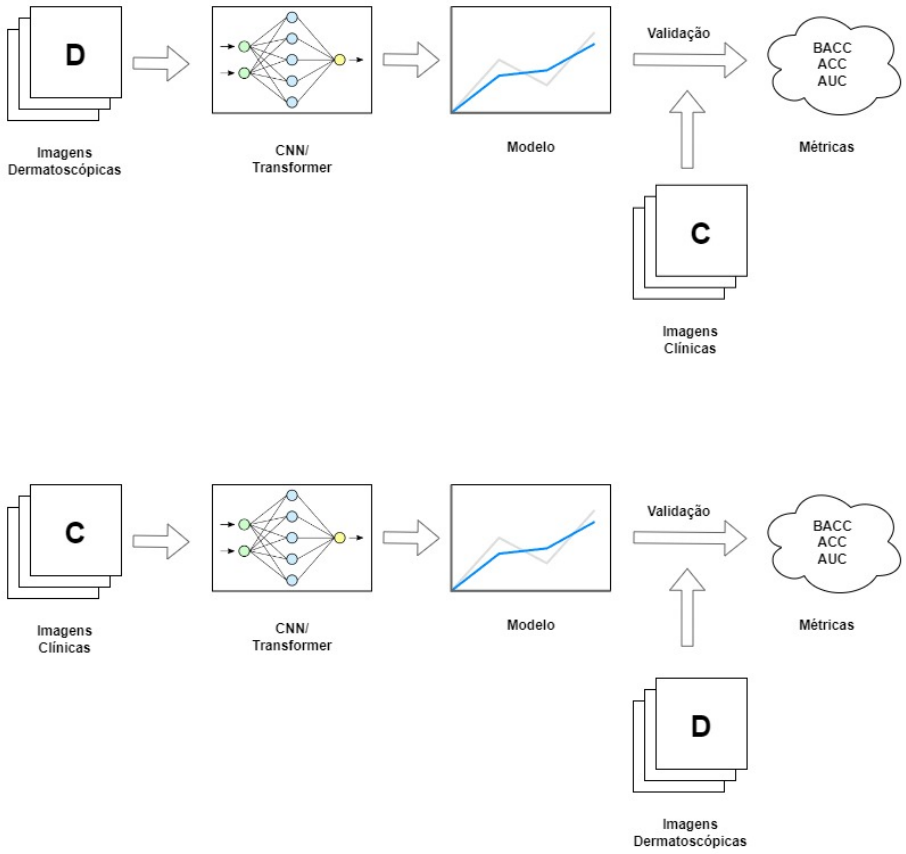
Esta abordagem testa diretamente a hipótese central do trabalho, que é a capacidade de um modelo treinado em um domínio de imagem generalizar seu conhecimento para outro. O objetivo aqui é quantificar a perda de performance que ocorre quando o modelo é exposto a um tipo de imagem diferente daquele para o qual foi otimizado. Os dois cenários de teste são:

1. **Treinamento Dermatoscópico, Teste Clínico:** O modelo é treinado com o conjunto consolidado de imagens dermatoscópicas (ISIC 2019 + PAD-UFES-20+ dermatoscópico) e, em seguida, avaliado no conjunto de teste de imagens clínicas do PAD-UFES-20+. Este cenário simula a aplicação de um modelo especialista (treinado com dados dermatoscópicos de alta observância dermatológica) em um ambiente clínico realista e de menor custo.

2. **Treinamento Clínico, Teste Dermatoscópico:** Invertendo o processo, o modelo é treinado com as imagens clínicas do PAD-UFES-20+ e avaliado no conjunto consolidado de imagens dermatoscópicas. Este experimento verifica se um modelo treinado na diversidade do mundo real pode extrair informações úteis de imagens com maior riqueza de detalhes.

A comparação dos resultados desta abordagem com a *baseline* permite medir o *domain shift* e a robustez de cada arquitetura.

Figura 10 – Figura ilustrativa da segunda abordagem



Fonte: Gerado pelo autor.

3.5.3 Abordagem 3: Análise de Treinamento Combinado

A última frente de investigação explora se a exposição simultânea a ambos os domínios durante o treinamento pode criar um modelo mais robusto e generalista. Nesta abordagem, todos os dados disponíveis (o *dataset* clínico e o *dataset* dermatoscópico unificado) são utilizados simultaneamente para treinar um único modelo.

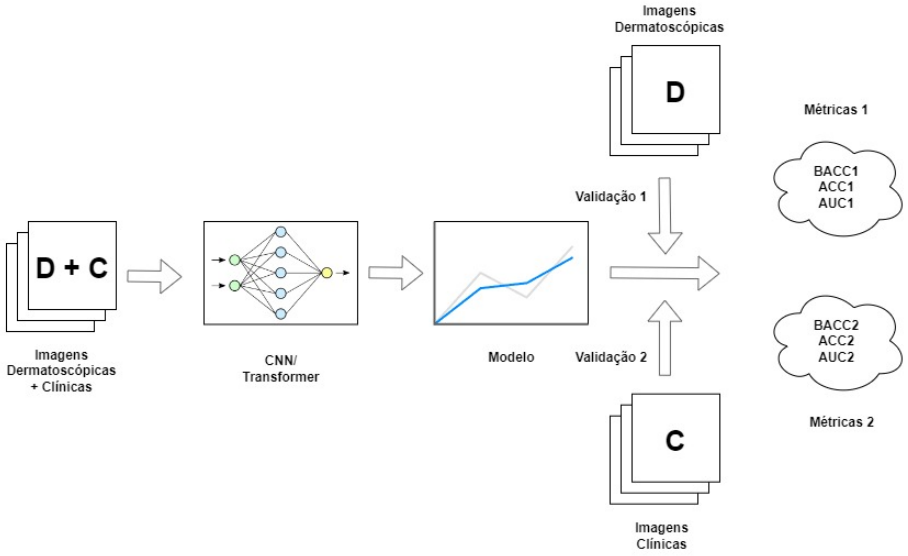
Após o treinamento, a avaliação é realizada de forma separada em cada um dos conjuntos de teste originais:

- O modelo treinado com dados combinados é avaliado no conjunto de teste de imagens clínicas do PAD-UFES-20+.
- O mesmo modelo é avaliado no conjunto de teste das imagens dermatoscópicas consolidadas.

O objetivo é verificar se o treinamento combinado resulta em uma melhoria de performance em um ou ambos os domínios quando comparado aos modelos treinados

individualmente na Abordagem 1.

Figura 11 – Figura ilustrativa da terceira abordagem



Fonte: Gerado pelo autor.

3.6 Metodologia de Treinamento e Validação

A etapa de treinamento foi projetada para garantir a reprodutibilidade dos experimentos e, fundamentalmente, para mitigar o risco de vazamento de dados (*data leakage*), um problema crítico em *datasets* médicos onde múltiplas imagens pertencem ao mesmo paciente.

3.6.1 Estratégia de Particionamento: *Stratified Group K-Fold*

Para a validação cruzada, adotou-se a estratégia *Stratified Group K-Fold* com $k = 5$. Diferente de uma divisão aleatória simples, esta abordagem impõe duas restrições simultâneas rigorosas no algoritmo de separação dos dados:

1. **Isolamento de Pacientes (Group):** Utilizando o identificador do paciente como chave de agrupamento, o algoritmo garante que todas as imagens de um mesmo indivíduo estejam contidas exclusivamente no conjunto de treinamento ou no conjunto de validação. Esse procedimento evita que o modelo memorize características biológicas intrínsecas ao paciente (como tom de pele ou marcas de nascença) em vez de aprender as características da lesão.

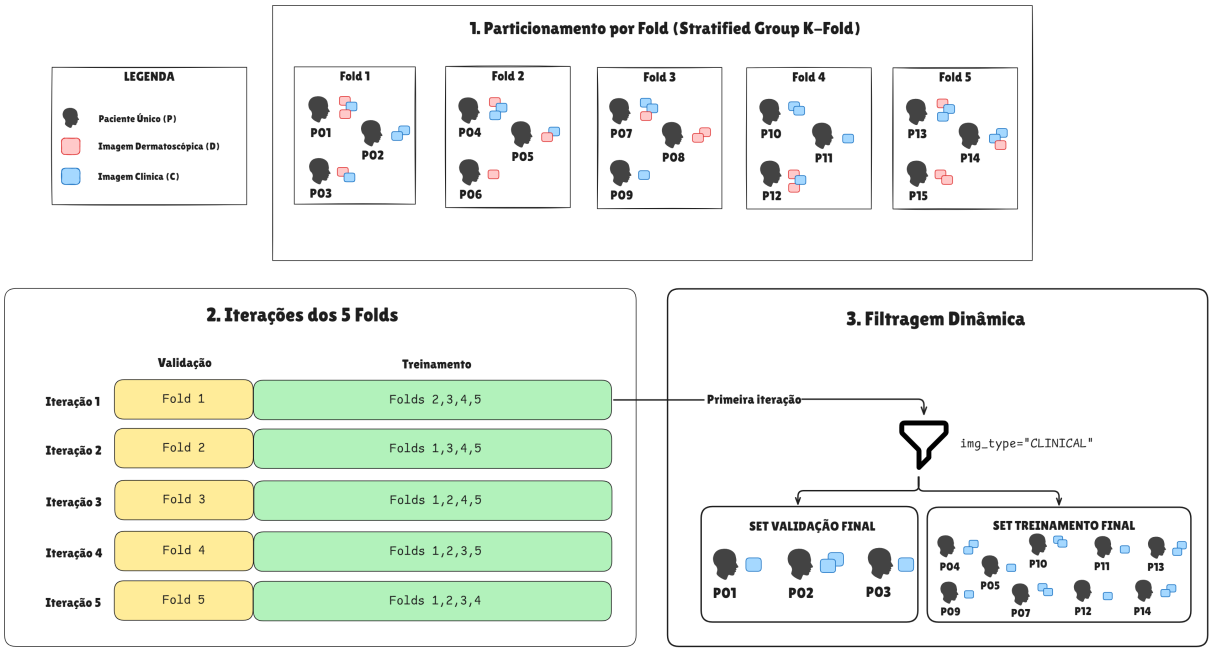
2. **Estratificação de Classes (Stratified):** O algoritmo busca manter a proporção original das classes diagnósticas em cada um dos cinco *folds*, assegurando que classes

minoritárias estejam representadas de forma equilibrada tanto no treino quanto na validação.

Uma característica crucial da implementação é a filtragem dinâmica. A definição dos índices de treinamento e validação é realizada sobre o *dataset* completo antes de qualquer segregação por modalidade. Somente após essa definição os dados são filtrados por tipo de imagem (e.g., clínica ou dermatoscópica). Isso garante a consistência experimental: os grupos de pacientes de validação permanecem os mesmos independentemente do domínio da imagem utilizado no experimento.

Para elucidar este processo, a Figura 12 exemplifica o fluxo metodológico aplicado a uma iteração de treinamento focada exclusivamente em imagens clínicas. O diagrama demonstra visualmente como o particionamento inicial (Etapa 1) preserva a totalidade das imagens de cada paciente nos respectivos folds. Subsequentemente, na Etapa 3, aplica-se o filtro para selecionar exclusivamente imagens do tipo *CLINICAL*, gerando os conjuntos finais de validação e treinamento sem violar o isolamento de pacientes estabelecido inicialmente.

Figura 12 – Fluxo do Stratified Group K-Fold com Filtragem Dinâmica



Fonte: Gerado pelo autor.

3.6.2 Pipeline de Processamento e *Data Augmentation*

A preparação dos dados é gerenciada por um pipeline customizado responsável por carregar as imagens, converter os rótulos diagnósticos para tensores numéricos e aplicar as transformações visuais.

Para o conjunto de treinamento, foi aplicado um processo robusto de aumento de dados (*Data Augmentation*) com o intuito de promover a generalização do modelo e a prevenção de *overfitting*. As transformações incluem:

- **Geométricas:** Recortes aleatórios com redimensionamento (*Random Resized Crop*), rotações, espelhamentos horizontais/verticais e distorções afins.
- **Cromáticas:** Variações aleatórias de brilho, contraste e saturação para simular diferentes condições de iluminação e dispositivos de captura.
- **Normalização:** Todas as imagens são padronizadas utilizando as médias e desvios padrão do *dataset* ImageNet.

Para o conjunto de validação, o pipeline de pré-processamento restringiu-se ao redimensionamento seguido do corte central (*Center Crop*). A adoção desta técnica, em detrimento do redimensionamento direto da imagem inteira, justifica-se pela necessidade crítica de preservar a dimensão original. O redimensionamento forçado poderia introduzir distorções artificiais, como a compressão de uma lesão circular em uma forma elíptica, o que comprometeria a capacidade do modelo de interpretar corretamente a morfologia da patologia. Diferente da etapa de treinamento, não foram aplicadas modificações aleatórias neste conjunto. Essa decisão visa garantir a reprodutibilidade das métricas de avaliação e simular fielmente o cenário de inferência em produção, onde o modelo deve classificar uma imagem estática e padronizada sem o auxílio de variações artificiais.

3.6.3 Configuração Experimental e Hiperparâmetros

A estratégia de aprendizado baseia-se na técnica de *Transfer Learning*. As redes neurais utilizadas no estudo foram inicializadas com pesos pré-treinados no *dataset* ImageNet. A camada de classificação original foi substituída por uma nova camada totalmente conectada (*fully connected*), com número de neurônios correspondente à quantidade de classes (8). Embora esta camada retorne valores brutos (*logits*), a função de ativação Softmax é aplicada internamente pela função de perda (*CrossEntropyLoss*) durante o treinamento e, na etapa de teste, é utilizada para converter esses valores nas probabilidades finais de cada diagnóstico.

A Tabela 2 resume o padrão de hiperparâmetros adotado para todos os experimentos, garantindo uma base de comparação justa entre diferentes arquiteturas.

Tabela 2 – Padronização dos hiperparâmetros e protocolos de treinamento.

Parâmetro	**Configuração / Comportamento**
Inicialização de Pesos	ImageNet (Pre-trained)
Otimizador	Adam
Taxa de Aprendizado (LR)	1×10^{-4}
Weight Decay	1×10^{-4}
Batch Size	32
Função de Perda	CrossEntropyLoss
Scheduler (Ajuste Dinâmico)	ReduceLROnPlateau: Monitora a *loss* de validação. Reduz a LR pela metade (fator=0.5) após 3 épocas sem melhoria.
Épocas Máximas	35
Critério de Parada	Early Stopping: Interrompe o treino após 10 épocas sem ganho na acurácia de validação, salvando apenas os melhores pesos (checkpoint).

4 Experimentos e Resultados

Neste capítulo, são apresentados e discutidos os resultados obtidos em cada um dos cenários experimentais propostos. A análise detalha o desempenho das arquiteturas avaliadas, com foco especial no modelo de melhor performance geral (ResNet-101), avaliando o impacto do hiato de domínio (*domain shift*). Por fim, é conduzida uma validação estatística rigorosa para avaliar a significância matemática dos achados.

4.1 Resultados e Discussão

Para fornecer uma visão completa do desempenho das arquiteturas avaliadas, a Tabela 3 sumariza as métricas obtidas em todos os cenários experimentais. A tabela segmenta os resultados por abordagem (Intra-Domínio, Inter-Domínio e Unificado) e destaca a média das métricas de Acurácia (ACC), Acurácia Balanceada (BACC) e AUC de cada modelo ao longo da validação cruzada.

Tabela 3 – Consolidação dos resultados obtidos em todas as abordagens experimentais.

Abordagem	**Cenário (Treino → Teste)**	**Modelo**	**ACC**	**BACC**	**AUC**
1. Intra-Domínio	Dermato → Dermato	MobileNetV3	83,75%	74,97%	0,97
		ViT-B/16	84,10%	76,50%	0,97
		ResNet-50	86,90%	80,74%	0,98
		ResNet-101	**88,02%**	**82,65%**	**0,98**
	Clínico → Clínico	MobileNetV3	76,26%	60,18%	0,93
		ViT-B/16	75,81%	58,46%	0,92
		ResNet-50	78,28%	62,22%	0,93
		ResNet-101	**78,47%**	**62,35%**	**0,92**
2. Inter-Domínio	Clínico → Dermato	MobileNetV3	34,64%	28,32%	0,66
		ViT-B/16	33,67%	28,12%	0,66
		ResNet-50	40,80%	31,16%	0,72
		ResNet-101	**43,80%**	**32,13%**	**0,72**
	Dermato → Clínico	MobileNetV3	28,46%	33,15%	0,67
		ViT-B/16	24,70%	30,63%	0,65
		ResNet-50	28,52%	32,91%	0,66
		ResNet-101	**30,62%**	**33,98%**	**0,68**
3. Unificado	Unificado → Dermato	MobileNetV3	82,95%	73,56%	0,97
		ViT-B/16	80,17%	72,06%	0,97
		ResNet-50	83,48%	76,43%	0,97
		ResNet-101	**87,07%**	**81,30%**	**0,98**
	Unificado → Clínico	MobileNetV3	75,57%	59,25%	0,92
		ViT-B/16	74,12%	55,09%	0,91
		ResNet-50	76,50%	61,79%	0,92
		ResNet-101	**77,78%**	**62,21%**	**0,92**

A análise subsequente detalha o comportamento do modelo de melhor desempenho

geral, a ResNet-101, para compreender as nuances de acertos e erros em cada abordagem.

4.1.1 Análise da Abordagem 1: Intra-Domínio

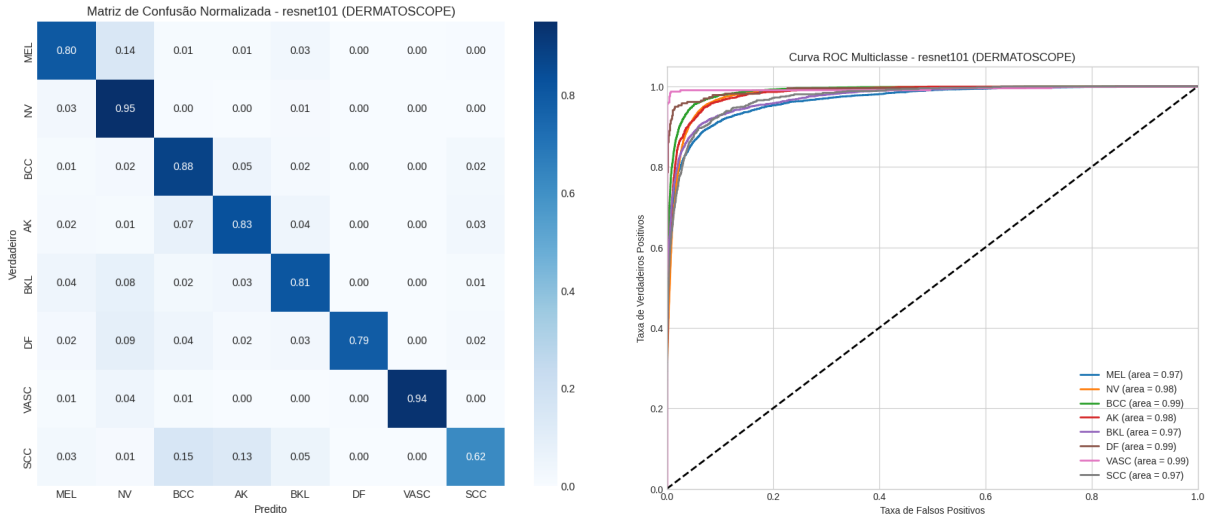
4.1.1.1 Domínio Dermastoscópico

Nas imagens dermatoscópicas, a ResNet-101 demonstrou desempenho consistente, atingindo uma Acurácia Balanceada de 82,65%. A Matriz de Confusão (Figura 13a) revela que o modelo foi capaz de identificar corretamente 80% dos Melanomas (*Recall* 0,80), confundindo os 20% restantes majoritariamente com NV. Esta confusão é esperada até mesmo entre especialistas humanos, podendo estar associada à existência de nevos atípicos que compartilham padrões dermatoscópicos com melanomas iniciais.

As Curvas ROC (Figura 13b) confirmam a robustez do classificador, com uma AUC de 0.97 para a classe MEL. Isso sugere que, por meio da riqueza de detalhes provida pela dermatoscopia (visualização de redes pigmentares e glóbulos), a rede neural apresenta maior aptidão para separar as distribuições de probabilidade das classes com margem segura.

Além disso, um ponto de destaque nesta modalidade refere-se à eficiência do modelo em classes minoritárias, como a VASC. Apesar de possuir o menor suporte do conjunto (253 imagens), a classe atingiu métricas de Precision e Recall de 0,94. Este resultado sugere que as estruturas vasculares visualizadas via dermatoscopia podem apresentar características altamente discriminativas, favorecendo o desempenho da rede mesmo com um volume reduzido de amostras.

Figura 13 – Desempenho da ResNet-101 no Domínio Dermatoscópico.



(a) Matriz de Confusão (b) Curvas ROC

Fonte: Gerado pelo autor.

4.1.1.2 Domínio Clínico

Ao migrar para o domínio clínico, observa-se uma tendência de calibração conservadora. A Matriz de Confusão (Figura 14a) expõe uma queda abrupta na sensibilidade para MEL, com um textcolorredvalor de apenas 0,43.

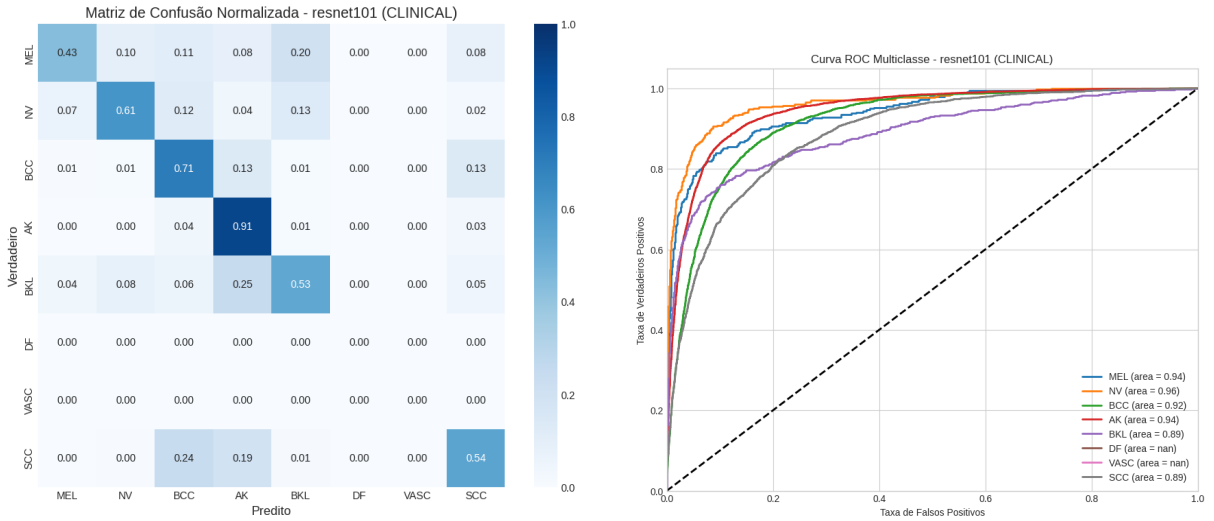
O dado mais expressivo refere-se à origem desse erro: uma confusão frequente com a classe BKL. Em fotografias clínicas, tanto o MEL quanto a Ceratose Seborreica (um tipo de BKL) manifestam-se frequentemente como lesões elevadas, escuras e com aparência de "verruga". Sem acesso às microestruturas da derme, o modelo pode apresentar maiores dificuldades em distinguir tais classes com precisão, o que pode favorecer estatisticamente a opção pela classe mais frequente ou morfologicamente similar (BKL).

Contudo, as Curvas ROC (Figura 14b) mostram que a AUC para MEL permaneceu extremamente alta (0,94). Esse resultado levanta um aspecto interessante: o modelo ordena bem os casos (dá probabilidade alta para MEL), mas não o suficiente para superar o limiar de decisão final (*argmax*) frente às outras classes. Isso sugere que o modelo aprendeu características discriminativas, mas opera em uma zona de incerteza onde um possível ajuste do limiar de decisão poderia ser investigado para priorizar a sensibilidade.

A influência do desbalanceamento de classes é evidente no desempenho da AK. Beneficiando-se do maior suporte no domínio clínico (9.190 imagens), a classe obteve o F1-score mais elevado (0,90), indicando que a abundância de dados permitiu ao modelo capturar a variabilidade visual das fotos clínicas com alta precisão.

Em contrapartida, a ausência completa das classes DF e VASC no conjunto de dados clínico (PAD-UFES) impacta negativamente a Acurácia Balanceada (BACC). Como a BACC é calculada pela média aritmética do *Recall* de todas as classes, a inexistência de amostras para estas categorias resulta em uma sensibilidade nula, impactando negativamente a média global. Esse fator ajuda a explicar o motivo pelo qual, embora a Acurácia Global seja satisfatória (78,47%), a Acurácia Balanceada sofre uma queda expressiva neste domínio (62,35%), refletindo a limitação do sistema em atuar sobre patologias que não foram apresentadas durante a fase de treinamento clínico.

Figura 14 – Desempenho da ResNet-101 no Domínio Clínico.



(a) Matriz de Confusão (b) Curvas ROC

Fonte: Gerado pelo autor.

4.1.2 Análise da Abordagem 2: Avaliação Inter-Domínio

Nesta etapa, a ResNet-101 foi novamente a arquitetura que obteve o melhor resultado ao ser submetida a testes de transferência de domínio para avaliar sua capacidade de generalização frente ao fenômeno de *domain shift*. Os resultados evidenciam que a especialização em uma modalidade de imagem cria barreiras estruturais para a interpretação da outra, resultando em uma redução expressiva das métricas de desempenho.

4.1.2.1 Cenário A: Treino Clínico → Teste Dermatoscópico

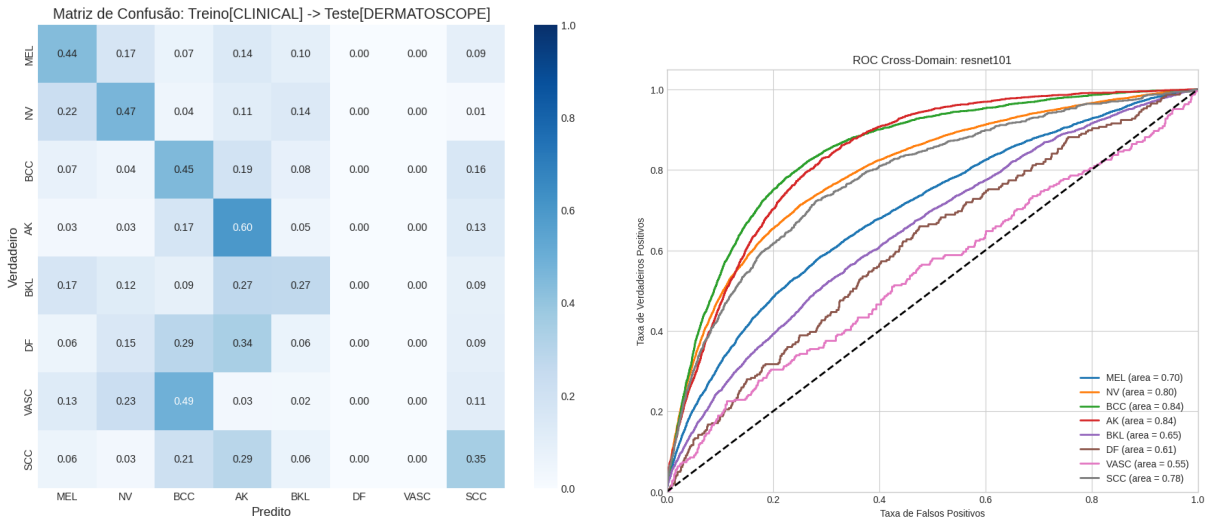
Neste cenário, avaliou-se a capacidade do modelo em aplicar o conhecimento obtido em fotografias macroscópicas para classificar imagens de alta resolução e iluminação controlada. A Acurácia Global registrou 43,80% (± 4,19%), enquanto a Acurácia Balanceada situou-se em 32,13% (± 1,27%).

A análise da Matriz de Confusão (Figura 15a) revela que a AK obteve o maior *Recall* entre as patologias (0,60). Este dado sugere que a forte representação aprendida para esta classe no domínio clínico (onde possui uma quantidade alta de 9.190 imagens) sobrevive parcialmente à mudança de escala. O MEL manteve um *Recall* de 0,44, valor muito próximo aos 0,43 registrados no teste intra-domínio clínico. Isso pode indicar que a rede direciona o foco para padrões visíveis a olho nu, como o formato e a cor da mancha, que não mudam entre os tipos de foto. Contudo, o modelo parece não utilizar os detalhes minuciosos revelados exclusivamente pelo dermatoscópio, limitando a utilização de informações complementares para um diagnóstico mais preciso.

As Curvas ROC (Figura 15b) confirmam a perda de separabilidade, com a AUC

do MEL caindo para 0,70. Além disso, observa-se a limitação do modelo para as classes DF e VASC, que apresentam *Recall* nulo (0,00) e AUC próxima à aleatoriedade (0,50 para VASC), uma vez que não possuem representatividade no domínio clínico de treinamento.

Figura 15 – Resultados da ResNet-101 no cenário Cross-Domain (Clínico → Dermatoscópico).



(a) Matriz de Confusão

(b) Curvas ROC

Fonte: Gerado pelo autor.

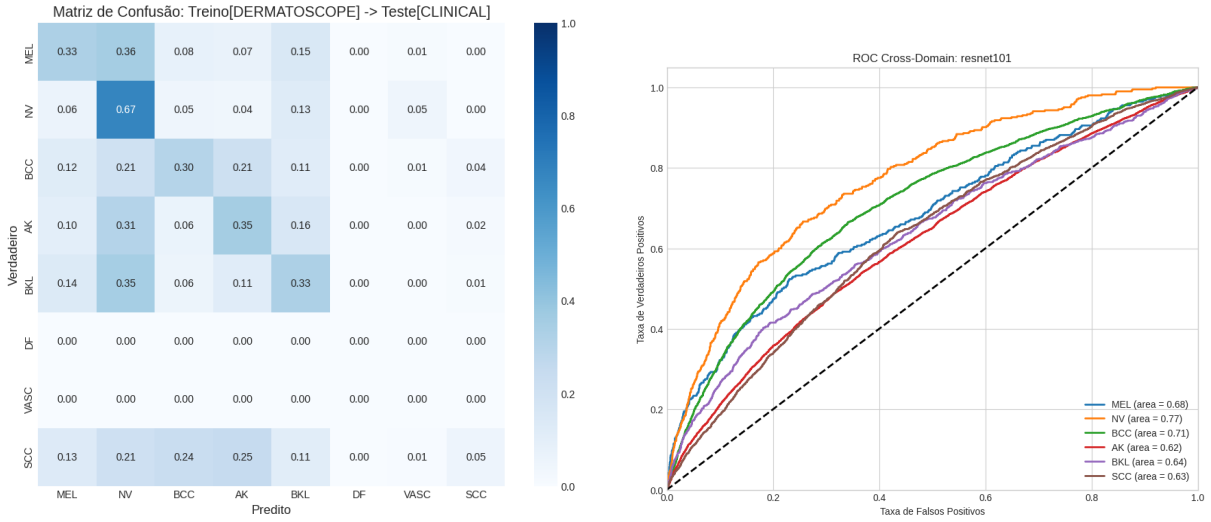
4.1.2.2 Cenário B: Treino Dermatoscópico → Teste Clínico

O cenário inverso (treinando com imagens dermatoscópicas e testando com imagens clínicas) demonstrou desafios significativos no estudo, resultando em uma queda da capacidade discriminativa do modelo. A Acurácia Global caiu para 30,62% (± 1,65%), com uma Acurácia Balanceada de 33,98% (± 1,54%).

A Matriz de Confusão (Figura 16a) sugere um viés para as classes majoritárias do treinamento dermatoscópico. O NV obteve um *Recall* de 0,67, porém com uma Precisão de apenas 0,06. Uma hipótese para este comportamento é que o modelo, treinado para buscar microestruturas como redes pigmentares e glóbulos, possa não encontrar tais "âncoras" visuais nas fotografias clínicas. Na ausência de sinais dermatoscópicos, a rede tende a convergir para a classe estatisticamente mais abundante, o que pode gerar um volume elevado de falsos positivos.

Para o MEL, o *Recall* regrediu para 0,33, com uma precisão igualmente baixa de 0,06. As Curvas ROC (Figura 16b) aproximam-se da linha diagonal de não-discriminação, com a AUC do MEL situando-se em 0,68.

Figura 16 – Resultados da ResNet-101 no cenário Cross-Domain (Dermatoscópico → Clínico).



(a) Matriz de Confusão

(b) Curvas ROC

Fonte: Gerado pelo autor.

É importante destacar que os resultados obtidos contrariaram a hipótese inicial de que modelos treinados no "padrão-ouro" (Dermatoscopia) seriam capazes de extrair características robustas o suficiente para generalizar em imagens clínicas. A redução das métricas pode ser justificada, primariamente, pela divergência na natureza da coleta de dados entre as bases utilizadas. Enquanto o dataset ISIC-2019 é constituído por imagens adquiridas em ambiente controlado, com iluminação padronizada e foco na lesão, o dataset PAD-UFES-20+ reflete o cenário prático real de triagem. As imagens clínicas deste conjunto apresentam alta variabilidade de exposição, desfoque e, frequentemente, contêm artefatos obstrutivos como pelos e reflexos de *flash*. Essa contaminação visual desloca a distribuição dos dados de teste para uma região que pode ser considerada *near-OOD* (near Out-Of-Distribution) em relação ao espaço de características aprendido durante o treino dermatoscópico. Consequentemente, a rede neural, com dificuldades de correlacionar os padrões do mundo real com as texturas livres de ruído do treinamento, sofre uma queda de desempenho que dificulta o uso direto sem estratégias de adaptação.

4.1.3 Análise da Abordagem 3: Treinamento Unificado

A terceira abordagem experimental fundamentou-se na hipótese de que a exposição simultânea a múltiplos domínios visuais (Dermatoscópico + Clínico) permitiria à rede neural aprender representações mais robustas e invariantes. Esperava-se, teoricamente, que a riqueza de detalhes das imagens dermatoscópicas atuasse como um regularizador, guiando o aprendizado de características discriminativas que pudessem ser transferidas para o domínio clínico.

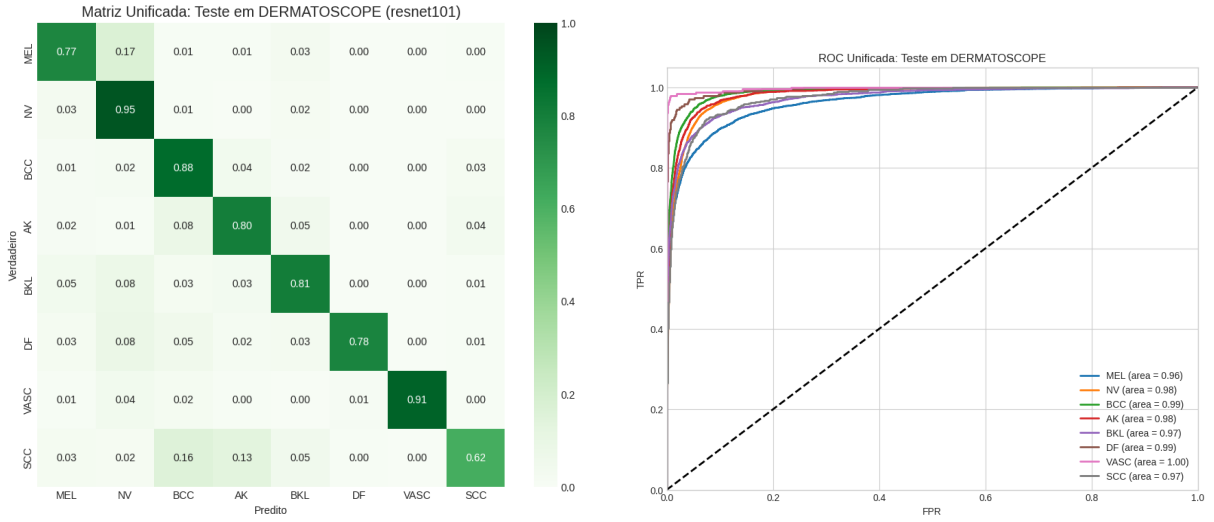
4.1.3.1 Desempenho no Domínio Dermatoscópico

Ao ser avaliado no conjunto de teste dermatoscópico, o modelo unificado ResNet-101 demonstrou alta competência, alcançando uma Acurácia Global de 87,07% (± 0,54%) e Acurácia Balanceada de 81,30% (± 1,19%).

O relatório detalhado evidencia que a rede manteve a capacidade de identificar microestruturas complexas. Destaca-se o desempenho na classe VASC, que, mesmo sendo uma classe minoritária, obteve um *Recall* de 0,91 e F1-Score de 0,93. Isso indica que o modelo foi capaz de aprender padrões vasculares específicos. O MEL apresentou um *Recall* de 0,77, indicando que a maioria das lesões malignas pigmentadas foi corretamente identificada, embora a confusão com os Nevos (NV) persista (Figura 17).

Quando comparado à Abordagem 1 (Especialista Intra-Domínio), observa-se uma leve retração no desempenho (a BACC original era 82,65%). Essa queda sugere que a inclusão de imagens clínicas, que possuem menor qualidade e maior ruído, durante o treinamento pode ter introduzido uma "interferência negativa" na otimização dos pesos.

Figura 17 – Resultados da ResNet-101 (Treino Unificado) testada no Domínio Dermatoscópico para a abordagem 3.



(a) Matriz de Confusão

(b) Curvas ROC

Fonte: Gerado pelo autor.

4.1.3.2 Desempenho no Domínio Clínico

No cenário clínico, o modelo registrou uma Acurácia Global de 77,78% (± 0,57%) e Acurácia Balanceada de 62,21% (± 1,54%).

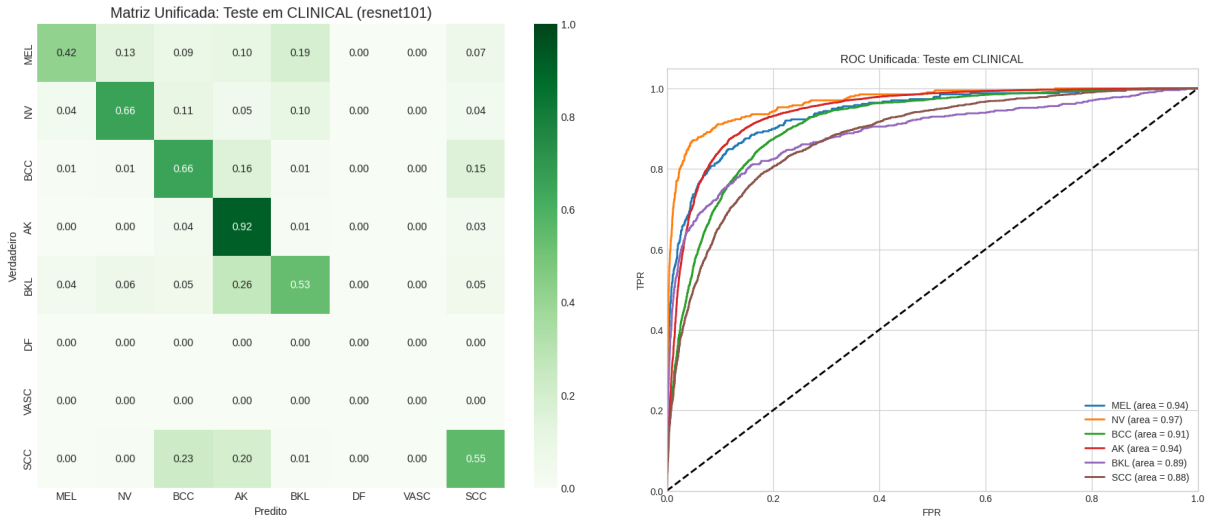
A análise por classe revela uma forte dependência da quantidade de dados. A AK, classe dominante neste domínio, atingiu o maior *Recall* do experimento (0.92). Em contrapartida, o MEL permaneceu com uma sensibilidade crítica de 0.42. A Matriz de

Confusão (Figura 18) mostra que o modelo apresenta dificuldades em distinguir MEL de BKL e NV, uma limitação potencialmente associada à ausência de visualização da derme em fotos macroscópicas.

Ao contrastar com a Abordagem 1 (Especialista Intra-Clínico: BACC 62,35%), constata-se que os resultados são estatisticamente semelhantes. A hipótese de que o acesso às imagens dermatoscópicas durante o treino auxiliaria o modelo a encontrar melhores padrões nas imagens clínicas não foi corroborada neste experimento. Há indícios de que o modelo tende a isolar os domínios de representação, utilizando um conjunto de características para analisar a dermatoscopia e outro distinto para as fotos clínicas, sem integrar os aprendizados para a formulação de um diagnóstico mais unificado.

Apesar de não superar o especialista, a vantagem dessa abordagem é revela-se na comparação com a Abordagem 2 (Inter-Domínio). Enquanto a transferência direta apresentou desempenho insatisfatório (BACC $\approx$ 33%), o treinamento unificado gerou um modelo robusto o suficiente para evitar a degradação das métricas, garantindo uma performance estável em ambos os cenários, ainda que sem ganhos de precisão diagnóstica em relação aos modelos dedicados.

Figura 18 – Resultados da ResNet-101 (Treino Unificado) testada no Domínio Clínico para a abordagem 3.



(a) Matriz de Confusão

(b) Curvas ROC

Fonte: Gerado pelo autor.

4.2 Validação Estatística: Teste de Wilcoxon

Para verificar se as diferenças observadas entre as médias de Acurácia Balanceada (BACC) das abordagens não são fruto do acaso, foi aplicado o teste não-paramétrico de postos sinalizados de Wilcoxon (*Wilcoxon Signed-Rank Test*). O teste foi realizado de

forma pareada, comparando os resultados obtidos em cada um dos 5 *folds* da validação cruzada para o modelo ResNet-101.

4.2.1 Cenário 1: Diagnóstico Clínico

O foco principal aqui é a aplicação em imagens clínicas. Os resultados comparativos a seguir resumem os testes de hipótese para este domínio, evidenciando o desafio de triagem.

- **A1 (Intra-Domínio) vs. A3 (Unificado → Clínico):**
  - Média A1: 0.6235 | Média A3: 0.6221
  - *P-valor*: 0.8125
  - **Análise:** O teste indicou um empate estatístico. A diferença entre as médias não se mostrou estatisticamente significativa no limiar adotado. Esse resultado corrobora a premissa de que o Modelo Unificado apresenta competência similar ao Especialista para classificar imagens clínicas, o que poderia reduzir a necessidade operacional de manter múltiplos modelos em produção.
- **A1 (Intra-Domínio) vs. A2 (Transferência Cruzada):**
  - Média A1: 0.6235 | Média A2: 0.3398
  - *P-valor*: 0.0625 (Piso estatístico para $n = 5$)
  - **Análise:** Embora o teste tenha retornado um valor marginalmente acima de 0,05, a análise das médias revela uma diferença prática expressiva ($\Delta \approx 28\%$). O modelo A1 superou o A2 em todos os *folds*. O resultado de 0,0625 não reflete ausência de efeito, mas sim o limite inferior estatístico imposto pelo número de *folds*. Os resultados sugerem a presença de um considerável hiato de domínio (*domain shift*): modelos treinados exclusivamente em dermatoscopia apresentaram limitações significativas na capacidade de generalizar para o domínio clínico sem adaptação.

4.2.2 Cenário 2: Diagnóstico Dermatoscópico

Avalia-se o impacto das diferentes estratégias no tipo de imagem mais padronizado.

- **A1 (Intra-Domínio) vs. A3 (Unificado → Dermato):**
  - Média A1: 0.8265 | Média A3: 0.8130
  - *P-valor*: 0.0625

  - **Análise:** O modelo Especialista venceu em todos os *folds*. A leve queda de desempenho no Unificado sugere uma interferência negativa causada pela inserção de imagens clínicas ruidosas no treinamento. Dessa forma, diferentemente do cenário clínico, no qual os modelos intra-domínio e unificado apresentam performances semelhantes, no contexto dermatoscópico observa-se uma diferença estatisticamente significativa.

- **A1 (Intra-Domínio) vs. A2 (Clínico → Dermato):**
  - Média A1: 0.8265 | Média A2: 0.3213
  - *P-valor*: 0.0625
  - **Análise:** Reforça-se a dificuldade da utilização de modelos treinados em imagens macroscópicas para classificar dermatoscopia, dada a ausência de aprendizado de microestruturas.

4.2.3 Cenário 3: O *Gap* de Domínio

Essa comparação isola o efeito da unificação em relação à transferência direta, avaliando se a integração dos dados mitiga o problema da generalização.

- **A3 (Unificado → Clínico) vs. A2 (Dermato → Clínico):**
  - Média A3: 0.6221 | Média A2: 0.3398
  - *P-valor*: 0.0625
  - **Análise:** Este é o resultado mais importante para justificar a Abordagem 3. O modelo A2 (Transferência) apresenta desempenho insatisfatório (33%). O modelo A3 (Unificado), ao ver exemplos de ambos os domínios durante o treino, restaura o desempenho para níveis adequados (62%). Embora o teste estatístico esbarre no limite amostral, a magnitude da diferença indica que a estratégia de unificação pode ser eficaz para mitigar o *Gap de Domínio* que a transferência simples não conseguiu transpor.

5 Considerações Finais

5.1 Conclusão

Os experimentos realizados permitiram avaliar a hipótese inicial de que a riqueza de detalhes das imagens dermatoscópicas impactaria positivamente a generalização de modelos de aprendizado profundo para diferentes modalidades. Embora as arquiteturas avaliadas, notadamente a ResNet-101, tenham atingido desempenho comparável ao estado da arte em cenários controlados (Intra-Domínio), a expectativa de que o conhecimento extraído da dermatoscopia refinasse a classificação de imagens clínicas não foi corroborada pelos resultados. A análise comparativa demonstrou que a transferência direta de conhecimento entre domínios visuais distintos resulta em uma redução expressiva das métricas de desempenho, evidenciando uma discrepância de características significativa causada pelo hiato de domínio (*domain shift*). Adicionalmente, a investigação sobre a unificação de bases (Abordagem 3) revelou que, embora o sistema mantenha a estabilidade e atinja resultados próximos aos do modelo especialista (Abordagem 1), a simples agregação de dados dermatoscópicos não promoveu o aprimoramento das métricas diagnósticas no cenário clínico. Esse comportamento sugere que a capacidade humana de correlacionar microestruturas com a macroscopia não é replicada de forma automática pelo modelo apenas por meio da exposição conjunta aos dados. Conclui-se, portanto, que a viabilização de sistemas robustos de triagem automática via *smartphone* exige abordagens que vão além da diversidade de modalidades de treinamento, demandando a implementação de técnicas explícitas de adaptação de domínio e a incorporação de dados multimodais para transpor a barreira imposta pela variação na qualidade visual.

5.2 Trabalhos Futuros

Com o objetivo de aproximar o sistema da prática médica e elevar a acurácia diagnóstica, sugere-se a implementação de uma abordagem multimodal. Essa estratégia consiste em fundir os vetores de características visuais extraídos pelas CNNs com os metadados clínicos presentes no dataset PAD-UFES-20+ (como idade e região anatômica) por meio de redes Perceptron Multicamadas (MLP). Adicionalmente, recomenda-se o refinamento da etapa de pré-processamento mediante a aplicação de segmentação semântica automática. A utilização de arquiteturas como a U-Net ou o modelo SAM (*Segment Anything Model*) possibilita o isolamento da região de interesse e a remoção de artefatos de fundo, direcionando a rede neural a focar exclusivamente na morfologia da lesão. Para mitigar a degradação de desempenho em cenários inter-domínio, propõe-se a investigação de técnicas de Adaptação

de Domínio Não Supervisionada. O emprego de Redes Adversárias Generativas (GANs), como a arquitetura CycleGAN, permitiria a tradução de estilo imagem-para-imagem, convertendo fotografias clínicas em representações "pseudo-dermatoscópicas".

Referências

DANDU, R.; MURTHY, M. V.; KUMAR, Y. R. Transfer learning for segmentation with hybrid classification to Detect Melanoma Skin Cancer. *Heliyon*, Elsevier Ltd, v. 9, 2023. Citado 2 vezes nas páginas 28 e 29.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: Transformers for image recognition at scale. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2021. Citado na página 25.

ESTEVA, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, Macmillan Publishers Limited, part of Springer Nature, v. 542, p. 115–118, 2017. Citado 4 vezes nas páginas 13, 14, 16 e 28.

HE, K. et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2016. p. 770–778. Citado na página 23.

International Skin Imaging Collaboration (ISIC). *Skin Lesion Analysis Towards Melanoma Detection*. 2019. <https://www.isic-archive.com>. Citado 2 vezes nas páginas 30 e 31.

K., C. et al. A Multiclass Skin Lesion classification approach using Transfer learning based convolutional Neural Network. In: *2021 Seventh International conference on Bio Signals, Images, and Instrumentation (ICBSII)*. [S.l.]: IEEE, 2021. Citado na página 28.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. In: PEREIRA, F. et al. (Ed.). *Advances in Neural Information Processing Systems 25*. [S.l.]: Curran Associates, Inc., 2012. p. 1097–1105. Citado 3 vezes nas páginas 17, 20 e 22.

LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998. Citado 2 vezes nas páginas 20 e 22.

M, A.; P, S. Deep learning for skin lesion classification using pre-trained neural networks. In: *2024 International Conference on Intelligent Algorithms for Computational Intelligence Systems (IACIS)*. [S.l.]: IEEE, 2024. Citado na página 29.

NASERI, H.; SAFAEI, A. A. Diagnosis and prognosis of melanoma from dermoscopy images using machine learning and deep learning: a systematic literature review. *BMC Cancer*, v. 25, n. 75, p. 1–25, 2025. Citado na página 13.

NAWAZ, K. et al. Skin cancer detection using dermoscopic images with convolutional neural network. *Scientific Reports*, Springer Nature, v. 15, n. 7252, mar 2025. Citado na página 27.

PACHECO, A. G. et al. PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, v. 32, p. 106221, 2020. ISSN 2352-3409. Citado 4 vezes nas páginas 26, 30, 32 e 33.

PACHECO, A. G. C.; KROHLING, R. A. An Attention-Based Mechanism to Combine

Images and Metadata in Deep Learning Models Applied to Skin Cancer Classification. *IEEE Journal of Biomedical and Health Informatics*, IEEE, v. 25, n. 9, p. 3554–3563, September 2021. Citado na página 27.

ROSENBLATT, F. Perceptrons and the theory of brain mechanisms. *Psychological Review*, American Psychological Association, v. 65, n. 6, p. 386–408, 1958. Citado na página 18.

SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2015. Citado na página 22.

Souza Jr., L. A. et al. LiwTERM: A Lightweight Transformer-based Model for Dermatological Multimodal Lesion Detection. In: *2024 37th SIBGRAPI Conference on Graphics, Patterns and Images (SIBGRAPI)*. [S.l.]: IEEE, 2024. Citado 2 vezes nas páginas 16 e 27.

SZEGEDY, C. et al. Going deeper with convolutions. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2015. p. 1–9. Citado na página 23.

VASWANI, A. et al. Attention is all you need. In: GUYON, I. et al. (Ed.). *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. [S.l.]: Curran Associates, Inc., 2017. p. 5998–6008. Citado 2 vezes nas páginas 23 e 24.

YOSINSKI, J. et al. How transferable are features in deep neural networks? In: *Advances in Neural Information Processing Systems 27 (NIPS 2014)*. [S.l.: s.n.], 2014. p. 3320–3328. Citado na página 21.

ZHANG, A. et al. *Dive into Deep Learning*. [S.l.]: Cambridge University Press, 2023. <https://D2L.ai>. Citado 5 vezes nas páginas 18, 19, 20, 21 e 25.